



GRADO EN INGENIERÍA MATEMÁTICA E INTELIGENCIA ARTIFICIAL

TRABAJO FIN DE GRADO

Modelo de predicción del éxito emprendedor en
franquicia a partir de perfiles psicométricos e
inteligencia artificial

Autor: Bernardo Ordás Cernadas

Director: Javier García Manzanedo

Madrid

Agosto de 2026



GRADO EN INGENIERÍA MATEMÁTICA E INTELIGENCIA ARTIFICIAL

TRABAJO FIN DE GRADO

Modelo de predicción del éxito emprendedor en
franquicia a partir de perfiles psicométricos e
inteligencia artificial

Autor: Bernardo Ordás Cernadas

Director: Javier García Manzanedo

Madrid

Agradecimientos

Este trabajo no habría sido posible sin la colaboración de las dos enseñanzas que accedieron a abrir sus procesos de selección y a ceder los datos de sus franquiciados para el estudio. A Brooklyn Fitboxing, y en particular a Cristina Pujol Buhigas, Pablo Ribadavia y Elena López; y a Japanese Head Spa, y en particular a Aida García Bueno, Silvia Conde y Ángela Maldonado. Su confianza y su disposición a compartir información sensible constituyen la base empírica sobre la que se sostiene toda la investigación.

Quiero agradecer igualmente a Hogrefe TEA Ediciones, y muy especialmente a Milagros Antón López, la cesión del uso de la Batería para la Evaluación de la Personalidad Emprendedora (BEPE), instrumento central de este trabajo. Y a Álvaro Postigo, autor de la Escala Grit de Oviedo (EGO), por cederla de forma desinteresada para su empleo en el estudio.

Quiero dar las gracias también a mi director, Javier García Manzanedo, por su orientación y su criterio a lo largo de todo el proyecto.

Por último, pero no por ello menos importante, me gustaría agradecerles a mis padres, Bernardo Ordás y Mercedes Cernadas, así como a mi pareja, María Kucker, su apoyo incondicional.

MODELO DE PREDICCIÓN DEL ÉXITO EMPRENDEDOR EN FRANQUICIA A PARTIR DE PERFILES PSICOMÉTRICOS E INTELIGENCIA ARTIFICIAL

Autor: Ordás Cernadas, Bernardo.

Director: García Manzanedo, Javier.

Entidad Colaboradora: Japanese Head Spa y Brooklyn Fitboxing (datos cedidos para el estudio).

RESUMEN DEL PROYECTO

Palabras clave: personalidad emprendedora, BEPE, grit, validez de criterio, aprendizaje estadístico, regresión logística, análisis de potencia, simulación Monte Carlo, restricción de rango.

1. Introducción

La actividad emprendedora es un motor del desarrollo económico, y la franquicia uno de sus vehículos más extendidos. Para el franquiciador, seleccionar bien a los franquiciados es crítico, y los instrumentos psicométricos de personalidad emprendedora se proponen como apoyo a esa decisión. Pese a la estandarización del modelo de negocio, la variabilidad de resultados entre franquiciados es alta y se atribuye en gran parte al factor humano, que sin embargo apenas se evalúa de forma sistemática. Este trabajo examina, sobre un caso real, hasta qué punto el perfil psicométrico permite anticipar el éxito del franquiciado.

2. Objetivos

El objetivo general es determinar la viabilidad de predecir el éxito en franquicia a partir de la batería BEPE, la escala de grit y variables sociodemográficas, sobre 41 candidatos de dos enseñas españolas. Más que obtener un modelo predictivo —desaconsejado por la literatura y el tamaño muestral—, se caracterizan las condiciones de señal y de muestra bajo las cuales la predicción sería posible y se sitúa el caso real respecto a ese umbral, garantizando una metodología honesta e interpretable.

3. Descripción del modelo/sistema/herramienta

Se construyó un perfil integrando las nueve variables psicométricas (ocho dimensiones BEPE más grit) y las sociodemográficas. La metodología combina cuatro bloques: un análisis univariante con tamaños del efecto e intervalos de confianza por bootstrap; una comparación de modelos de clasificación (regresión logística regularizada y gradient boosting) bajo validación cruzada honesta; un diagnóstico de mecanismos mediante la corrección de Thorndike por restricción de rango y un análisis de potencia; y un estudio de simulación Monte Carlo calibrado sobre los parámetros bifactor publicados de la BEPE, que mide la potencia del propio procedimiento en función del tamaño del efecto y de la muestra.

4. Resultados

- El análisis univariante no halla asociaciones estimables con el criterio (la mayor, tolerancia al estrés, $r = -0,218$, con intervalo que incluye el cero). Los modelos no discriminan por encima del azar (AUC validado $\approx 0,29$ frente a hasta $0,89$ de resustitución; permutación no significativa, $p = 0,869$). La corrección de Thorndike apenas desatenúa las correlaciones, y el efecto mínimo detectable con la muestra es $d = 0,93$. La simulación cifra en $0,104$ la potencia para un efecto realista ($d = 0,35$), que no alcanza $0,80$ ni con $n = 500$; el resultado es robusto en ocho variantes de sensibilidad.

5. Conclusiones

La ausencia de capacidad predictiva detectable es la consecuencia esperable y cuantificada de una señal débil examinada en condiciones desfavorables —efecto pequeño de origen, error de medida, restricción de rango e infrapotencia—, y no un fallo del método. El trabajo aporta un marco reproducible para evaluar la viabilidad de la predicción psicométrica y cuantifica el tamaño muestral que requeriría; su valor metodológico es independiente del signo del resultado.

6. Referencias

- [1] M. Cuesta, J. Suárez-Álvarez, L. M. Lozano, E. García-Cueto, and J. Muñoz, “Assessment of eight entrepreneurial personality dimensions: Validity evidence of the BEPE battery,” *Frontiers in Psychology*, vol. 9, Art. no. 2352, 2018.
- [2] A. Rauch and M. Frese, “Let’s put the person back into entrepreneurship research: A meta-analysis on the relationship between business owners’ personality traits, business creation, and success,” *European Journal of Work and Organizational Psychology*, vol. 16, no. 4, pp. 353–385, 2007.
- [3] Á. Postigo, M. Cuesta, and E. García-Cueto, “Entrepreneurial personality, conscientiousness, self-control, and grit: The psychological side of self-employment,” *Anales de Psicología*, vol. 37, no. 2, pp. 361–370, 2021.

PREDICTIVE MODEL OF ENTREPRENEURIAL SUCCESS IN FRANCHISING BASED ON PSYCHOMETRIC PROFILES AND ARTIFICIAL INTELLIGENCE

Author: Ordás Cernadas, Bernardo.

Supervisor: García Manzanedo, Javier.

Collaborating Entity: Japanese Head Spa and Brooklyn Fitboxing (data provided for the study).

ABSTRACT

Keywords: entrepreneurial personality, BEPE, grit, criterion validity, statistical learning, logistic regression, power analysis, Monte Carlo simulation, range restriction.

1. Introduction

Entrepreneurship is a driver of economic development, and franchising one of its most widespread vehicles. For the franchisor, selecting franchisees well is critical, and entrepreneurial-personality assessment tools are proposed to support that decision. Despite the standardisation of the business model, outcome variability across franchisees is high and largely attributed to the human factor, which is nonetheless rarely assessed systematically. This work examines, on a real case, to what extent the psychometric profile can anticipate franchisee success.

2. Objectives

The general aim is to determine the feasibility of predicting franchise success from the BEPE battery, a grit scale and sociodemographic variables, on 41 candidates from two Spanish brands. Rather than obtaining a predictive model—discouraged by the literature and the sample size—the work characterises the signal and sample-size conditions under which prediction would be possible and locates the real case relative to that threshold, ensuring an honest and interpretable methodology.

3. Description of the proposed model/system/tool

A profile was built integrating the nine psychometric variables (eight BEPE dimensions plus grit) and the sociodemographic ones. The methodology combines four blocks: a univariate analysis with effect sizes and bootstrap confidence intervals; a comparison of classification models (regularised logistic regression and gradient boosting) under honest cross-validation; a mechanism diagnosis via Thorndike's range-restriction correction and a power analysis; and a Monte Carlo simulation calibrated on the published bifactor parameters of the BEPE, measuring the procedure's own power as a function of effect size and sample size.

4. Results

Univariate analysis finds no estimable associations with the criterion (the largest, stress tolerance, $r = -0.218$, interval including zero). Models do not discriminate above chance (validated AUC ≈ 0.29 versus up to 0.89 in resubstitution; non-significant permutation, $p = 0.869$). Thorndike's correction barely de-attenuates the correlations, and the minimum detectable effect is $d = 0.93$. The simulation places power for a realistic effect ($d = 0.35$) at 0.104, not reaching 0.80 even at $n = 500$; the result is robust across eight sensitivity variants.

5. Conclusions

The absence of detectable predictive capacity is the expected, quantified consequence of a weak signal examined under unfavourable conditions —small underlying effect, measurement error, range restriction and underpowering— and not a failure of the method. The work provides a reproducible framework to assess the feasibility of psychometric prediction and quantifies the sample size it would require; its methodological value is independent of the sign of the result.

6. References

- [1] M. Cuesta, J. Suárez-Álvarez, L. M. Lozano, E. García-Cueto, and J. Muñoz, “Assessment of eight entrepreneurial personality dimensions: Validity evidence of the BEPE battery,” *Frontiers in Psychology*, vol. 9, Art. no. 2352, 2018.
- [2] A. Rauch and M. Frese, “Let’s put the person back into entrepreneurship research: A meta-analysis on the relationship between business owners’ personality traits, business creation, and success,” *European Journal of Work and Organizational Psychology*, vol. 16, no. 4, pp. 353–385, 2007.
- [3] Á. Postigo, M. Cuesta, and E. García-Cueto, “Entrepreneurial personality, conscientiousness, self-control, and grit: The psychological side of self-employment,” *Anales de Psicología*, vol. 37, no. 2, pp. 361–370, 2021.

Índice de la memoria

Capítulo 1. Introducción y motivación	1
1.1 Contexto y problema	1
1.2 La pregunta de investigación y el enfoque adoptado	2
1.3 Carácter interdisciplinar del trabajo	3
1.4 Contribuciones.....	3
1.5 Estructura de la memoria.....	4
1.6 Alineación con los Objetivos de Desarrollo Sostenible	5
Capítulo 2. Fundamentos de psicometría	7
2.1 Qué mide un test: la teoría clásica de los tests	7
2.2 Fiabilidad: la proporción de varianza verdadera	7
2.3 Puntuaciones directas, percentiles y baremos	8
2.4 Validez: evidencias de constructo y de criterio.....	9
2.5 El modelo bifactor como modelo de variables latentes.....	10
2.6 El constructo de personalidad emprendedora y su evolución.....	11
Capítulo 3. Fundamentos de aprendizaje estadístico	13
3.1 El problema de aprendizaje supervisado	13
3.2 La regresión logística como objeto matemático	14
3.2.1 Estimación por máxima verosimilitud.....	14
3.2.2 Gradiente (ecuaciones de score) y matriz hessiana	15
3.2.3 El algoritmo de Newton-Raphson e IRLS.....	15
3.2.4 La frontera de decisión.....	16
3.3 El régimen de muestra pequeña: separación y la necesidad de regularizar	17
3.4 Sesgo, varianza y complejidad muestral	17
3.5 Evaluación honesta del rendimiento.....	18
3.6 Restricción de rango.....	19
3.7 Potencia estadística y detectabilidad	20
3.8 Interpretabilidad y uso responsable de los modelos	20
Capítulo 4. Datos y metodología	22
4.1 Instrumentos y materiales.....	22

4.1.1 La Batería para la Evaluación de la Personalidad Emprendedora (BEPE)	22
4.1.2 La Escala Grit de Oviedo (EGO)	24
4.1.3 El cuestionario sociodemográfico ad hoc	25
4.2 La muestra: las franquicias y los candidatos	25
4.3 Variables.....	27
4.4 Operacionalización del criterio de éxito.....	27
4.5 Consideraciones éticas y protección de datos	28
4.6 Verificaciones de integridad.....	29
4.7 Plan de análisis prerregistrado.....	29
Capítulo 5. Resultados.....	31
5.1 Análisis exploratorio	31
5.1.1 Descriptivos y estructura de los predictores	31
5.1.2 Efecto techo: contraste con las normas poblacionales	32
5.1.3 Relación univariante con el criterio.....	33
5.1.4 Verificación de robustez: inversión de etiquetas.....	34
5.2 Modelización predictiva.....	35
5.2.1 Diseño de la comparación.....	35
5.2.2 Rendimiento de los modelos	35
5.2.3 Significación y validez incremental.....	36
5.3 Diagnóstico de mecanismos	37
5.3.1 Restricción de rango: corrección de Thorndike.....	37
5.3.2 Infrapotencia: efecto mínimo detectable y tamaño muestral requerido.....	39
5.4 Simulación de Monte Carlo.....	40
5.4.1 Diseño del generador	41
5.4.2 Validación del generador.....	42
5.4.3 Potencia del procedimiento, curva de aprendizaje y mapa de detectabilidad	42
5.4.4 Análisis de sensibilidad	44
Capítulo 6. Discusión	45
6.1 Interpretación de los resultados a la luz de la literatura	45
6.2 La cadena de mecanismos	46
6.3 Implicaciones para la práctica de la selección.....	47
6.4 Amenazas a la validez de este trabajo	47

Capítulo 7. Conclusiones y líneas futuras	50
7.1 Conclusiones	50
7.2 Limitaciones	51
7.3 Líneas futuras	51
Referencias	54
Anexos	57
Anexo A. Código y reproducibilidad.....	57
Anexo B. Tablas completas y diagnósticos de la simulación	57
Anexo C. Plan de análisis prerregistrado	57
Anexo D. Conjunto de datos seudonimizado y procedimiento de seudonimización	58

Índice de figuras

Figura 1. Saturación de las dimensiones BEPE frente a las normas poblacionales: porcentaje de la muestra en percentiles altos (efecto techo).	32
Figura 2. Distribución nula del AUC por permutación, con el AUC observado señalado..	37
Figura 3. Corrección de Thorndike por restricción de rango: correlaciones observadas frente a corregidas.....	38
Figura 4. Curva de potencia frente al tamaño muestral para distintos tamaños del efecto, con el efecto mínimo detectable de la muestra.....	40
Figura 5. Validación del generador: calibración de las puntuaciones simuladas frente a la muestra real.....	41
Figura 6. Mapa de detectabilidad: potencia del procedimiento según tamaño muestral y tamaño del efecto, con el caso real señalado.	42
Figura 7. Análisis de sensibilidad: potencia para un efecto realista ($d = 0,35$) en las distintas variantes del generador.....	43

Índice de tablas

Tabla 1. Estadísticos descriptivos de las variables psicométricas y sociodemográficas (media, desviación típica, mínimo y máximo).	31
Tabla 2. Correlaciones punto-biserials de cada variable con el criterio, con intervalo de confianza al 95 %, valor p y tamaño del efecto (d de Cohen).	33
Tabla 3. Rendimiento de los modelos de clasificación: AUC de resustitución frente a AUC validado (LOO).	35
Tabla 4. Corrección de Thorndike por restricción de rango: desviaciones típicas, ratio U y correlaciones observada y corregida por dimensión.	38
Tabla 5. Análisis de potencia: tamaño del efecto, AUC teórico equivalente y tamaño muestral requerido por grupo y total.	39
Tabla 6. Potencia del procedimiento estimada por simulación según el tamaño muestral, para distintos tamaños del efecto y el control de error de tipo I.	43

Capítulo 1. INTRODUCCIÓN Y MOTIVACIÓN

1.1 CONTEXTO Y PROBLEMA

La actividad emprendedora se considera un motor del desarrollo económico, y la franquicia es uno de sus vehículos más extendidos: permite a un emprendedor incorporarse a un modelo de negocio probado a cambio de operar bajo una marca y unas normas comunes. Desde la óptica del franquiciador, seleccionar bien a los franquiciados es crítico, porque el fracaso de una unidad daña la rentabilidad y la reputación de toda la red. De ahí el interés por cualquier herramienta que prometa anticipar qué candidatos tendrán éxito.

Entre esas herramientas figuran los instrumentos psicométricos de evaluación de la personalidad emprendedora. La psicología de las diferencias individuales ha identificado un conjunto de rasgos —autoeficacia, autonomía, innovación, motivación de logro, tolerancia al riesgo y otros— asociados teóricamente al espíritu emprendedor [1], y ha desarrollado cuestionarios para medirlos. En el ámbito español, la batería BEPE [2] es el instrumento de referencia. A ello se añade el constructo de grit, la perseverancia y pasión por objetivos a largo plazo [3], que se ha vinculado al desempeño en contextos exigentes. La pregunta natural, y la que motiva este trabajo, es si estas variables —junto a las sociodemográficas habituales en selección, como la edad o la experiencia previa— permiten predecir el éxito de un franquiciado.

El interés de esta pregunta se ve reforzado por una brecha conocida entre la evidencia y la práctica. Aunque la franquicia estandariza el modelo de negocio, los manuales operativos y el apoyo de la central, la variabilidad de resultados entre franquiciados es elevada, y buena parte de esa variabilidad se atribuye al factor humano. Paradójicamente, ese factor sigue siendo uno de los menos evaluados de forma sistemática en los procesos reales de selección de franquiciados, donde suelen predominar los criterios financieros, la experiencia previa o las entrevistas no estructuradas. La evaluación psicométrica se propone, en este contexto, como una vía para incorporar el factor humano de manera objetiva y comparable. Este

trabajo examina, precisamente, hasta qué punto esa promesa se sostiene empíricamente en un caso real.

1.2 LA PREGUNTA DE INVESTIGACIÓN Y EL ENFOQUE ADOPTADO

Una primera formulación del problema sería: *constrúyase un modelo que, a partir del perfil psicométrico y sociodemográfico de un candidato, prediga su éxito*. Este trabajo sostiene que esa formulación es, tal cual, metodológicamente imprudente, y que la pregunta correcta es previa: **¿es siquiera viable predecir el éxito en este contexto, con estos instrumentos y con los datos disponibles?**

La razón de este giro es doble. En primer lugar, la propia literatura advierte que la capacidad de los rasgos de personalidad para predecir la conducta emprendedora es modesta: en el estudio de validación de la BEPE, con 1.170 adultos, las dimensiones explicaban en torno al 5 % de la varianza de la condición de autónomo, mientras predecían de forma casi perfecta la pertenencia a grupos extremos de otro test de personalidad [2]. De forma aún más contundente, la tesis doctoral que integra el programa de investigación de la BEPE concluye que la personalidad emprendedora predice en torno a un 2,6 % de la varianza de llegar a convertirse en emprendedor [4]. El instrumento predice tests; apenas predice conducta. En segundo lugar, las condiciones de los datos en un proceso de selección real —muestra pequeña, candidatos preseleccionados, criterio de éxito de definición incierta— son precisamente las que la teoría del aprendizaje estadístico señala como adversas para la generalización. Anunciar un predictor en estas condiciones, y presentar como logro un modelo que en realidad sobreajusta el ruido de la muestra, sería el error que este trabajo busca evitar y, de hecho, examinar.

Por ello el trabajo se plantea como un **estudio de viabilidad y de caracterización de límites**. Su valor no reside en entregar un clasificador que funcione —se anticipa que no lo habrá—, sino en tres aportaciones de naturaleza metodológica: establecer con rigor el resultado predictivo, diagnosticar cuantitativamente sus causas, y prescribir las condiciones de un estudio futuro que sí fuera concluyente. Esta reformulación, lejos de rebajar la ambición del

trabajo, lo alinea con la práctica científica seria: un resultado negativo correctamente establecido es conocimiento, y a menudo más útil que un resultado positivo frágil.

Este enfoque es además plenamente coherente con el proyecto aprobado. La propuesta de Trabajo de Fin de Grado, firmada por autor y director, define explícitamente el carácter **exploratorio** del proyecto, reconoce que el acceso a datos reales es limitado y que el tamaño muestral no permite aspirar a métricas predictivas definitivas, y establece como prioridad la robustez metodológica, la interpretabilidad de los resultados y la coherencia teórica frente a la optimización de indicadores de rendimiento. El presente trabajo desarrolla ese planteamiento hasta sus últimas consecuencias: cuando los datos no permiten un predictor válido, la contribución honesta es demostrarlo con rigor y caracterizar lo que haría falta para lograrlo.

1.3 CARÁCTER INTERDISCIPLINAR DEL TRABAJO

El Trabajo se sitúa en la intersección de dos disciplinas. Del lado de la psicometría, toma los instrumentos, los constructos y el marco de la validez de los tests. Del lado de la ingeniería matemática y la inteligencia artificial, aporta la formalización del problema como aprendizaje supervisado, el aparato de la teoría del aprendizaje estadístico, los protocolos de validación honesta y la simulación Monte Carlo. Dado que el lector previsible —un tribunal de un grado de ingeniería— no tiene por qué estar familiarizado con la psicometría, el Capítulo 2 introduce sus conceptos desde su formulación matemática; y dado que el problema aplicado da sentido a las técnicas, el Capítulo 3 las presenta orientadas a la pregunta concreta de este trabajo. El equilibrio entre ambos capítulos es deliberado.

1.4 CONTRIBUCIONES

El trabajo realiza las siguientes contribuciones:

C1. Una evaluación rigurosa de la relación entre las variables psicométricas y sociodemográficas y el éxito en franquicia, con cuantificación de la incertidumbre y verificación de robustez frente a errores de codificación del criterio.

C2. Una comparación de la capacidad predictiva de distintas familias de modelos bajo validación honesta, que separa la limitación atribuible a la información de los datos de la atribuible a la elección del modelo.

C3. Un diagnóstico cuantitativo de los mecanismos que limitan la predicción —restricción de rango e infrapotencia estadística—, articulando la corrección de Thorndike y el análisis de potencia.

C4. Un estudio de simulación Monte Carlo calibrado sobre los parámetros bifactor publicados de la BEPE, que estima la potencia del procedimiento completo y prescribe el tamaño muestral necesario para un estudio concluyente.

C5. Una valoración de la validez incremental del bloque psicométrico sobre el sociodemográfico y del grit sobre la batería, con implicaciones para la práctica de la selección de personal.

C6. Un análisis del uso responsable e interpretable de modelos de aprendizaje automático en decisiones de alto impacto humano, mostrando cómo las técnicas de interpretabilidad operan, ante la ausencia de señal detectable, como herramienta de diagnóstico (evidenciando que ningún predictor contribuye de forma estable) y no como justificación de un sistema de decisión.

1.5 ESTRUCTURA DE LA MEMORIA

El Capítulo 2 introduce los fundamentos de psicometría necesarios. El Capítulo 3 desarrolla los fundamentos de aprendizaje estadístico, con la regresión logística como objeto central. El Capítulo 4 describe los datos y la metodología, incluyendo el plan de análisis prerregistrado. El capítulo 5 presenta los resultados, organizados en cuatro bloques: análisis

exploratorio y relación con el criterio (5.1), modelización predictiva comparada (5.2), diagnóstico de mecanismos (5.3) y estudio de simulación (5.4). El Capítulo 6 discute los hallazgos a la luz de la literatura, y el Capítulo 7 recoge las conclusiones, limitaciones y líneas futuras.

1.6 ALINEACIÓN CON LOS OBJETIVOS DE DESARROLLO SOSTENIBLE

El trabajo se alinea con varios Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030. Conviene precisar que esa alineación se formula en coherencia con el resultado del estudio —de carácter exploratorio y con conclusión predictiva negativa—, de modo que las contribuciones se plantean en términos de uso responsable y de generación de conocimiento metodológico, y no de un sistema de predicción en funcionamiento.

ODS 8 (Trabajo decente y crecimiento económico). Las decisiones de selección de franquiciados afectan a los medios de vida de los emprendedores. Al establecer las condiciones bajo las cuales la evaluación psicométrica tendría validez predictiva —y al mostrar que, sin ellas, no la tiene—, el trabajo promueve que esas decisiones se apoyen en evidencia sólida y no en herramientas no validadas, contribuyendo a procesos de selección más justos y a iniciativas empresariales mejor fundadas.

ODS 9 (Industria, innovación e infraestructura). El trabajo aporta una aplicación rigurosa de la teoría del aprendizaje estadístico y, en particular, un generador de simulación calibrado reutilizable para el diseño de estudios de validación predictiva, una contribución metodológica transferible a otros contextos de evaluación del talento.

ODS 4 (Educación de calidad). El tratamiento riguroso de un resultado negativo —distinguir la ausencia de efecto de la incapacidad de detectarlo, evitar el sobreajuste, comunicar la incertidumbre— constituye en sí mismo un ejercicio formativo sobre ciencia de datos responsable, y ofrece a emprendedores y evaluadores una comprensión más realista del alcance de la evaluación psicométrica.

ODS 10 (Reducción de las desigualdades). El trabajo advierte de un riesgo de equidad poco reconocido: emplear un instrumento no validado localmente en decisiones de selección puede revestir de aparente objetividad una discriminación sin fundamento. Al demostrar la ausencia de validez de criterio en este uso y cuantificar las condiciones para una validación legítima, contribuye a prevenir decisiones pseudoobjetivas y a fomentar una evaluación más equitativa.

Capítulo 2. FUNDAMENTOS DE PSICOMETRÍA

Este capítulo presenta los conceptos psicométricos que el resto del trabajo emplea, formulados en el lenguaje de un lector con formación matemática. No pretende ser una revisión exhaustiva de la disciplina, sino fijar con precisión las nociones de medida, fiabilidad, puntuación normativa y validez que sustentan la interpretación de los datos.

2.1 QUÉ MIDE UN TEST: LA TEORÍA CLÁSICA DE LOS TESTS

Un test psicométrico es un procedimiento para asignar un número a una característica no directamente observable de una persona —un *constructo*— como la autoeficacia o la tolerancia al riesgo. La teoría clásica de los tests (TCT) modela la puntuación observada en un test, X , como la suma de dos componentes no observables: una puntuación verdadera, V , que es el valor real del constructo en la persona, y un error de medida, E :

$$X = V + E, \quad E[E] = 0, \quad \text{Cov}(V, E) = 0$$

El error se supone aleatorio, de media cero e independiente de la puntuación verdadera. De este modelo se sigue que la varianza observada se descompone en varianza verdadera más varianza de error, $\sigma^2(X) = \sigma^2(V) + \sigma^2(E)$, una identidad que está en la base del concepto de fiabilidad. La TCT es un modelo a nivel de puntuación total; existen marcos más finos a nivel de ítem (la teoría de respuesta al ítem, que se menciona en el Capítulo 3 y en las líneas futuras), pero la TCT es suficiente para el tratamiento que aquí se hace, dado que los datos disponibles son puntuaciones de escala y no respuestas a ítems individuales.

2.2 FIABILIDAD: LA PROPORCIÓN DE VARIANZA VERDADERA

La fiabilidad de un test es la proporción de la varianza observada que corresponde a varianza verdadera:

$$\rho = \frac{\sigma^2(V)}{\sigma^2(X)} = 1 - \frac{\sigma^2(E)}{\sigma^2(X)} \in [0,1]$$

Un test perfectamente fiable ($\rho = 1$) no tiene error de medida; uno completamente no fiable ($\rho = 0$) es puro ruido. Como la puntuación verdadera es inobservable, la fiabilidad se estima por procedimientos indirectos. El más habitual es el coeficiente alfa de Cronbach [5], que aprovecha la consistencia interna entre los ítems de una escala; una alternativa con mejores propiedades es el omega de McDonald [6], basado en el modelo factorial subyacente. A efectos prácticos, ambos toman valores en $[0, 1]$ y se consideran adecuados a partir de 0,80. La batería empleada en este trabajo presenta fiabilidades publicadas entre 0,81 y 0,89 por escala [2], lo que indica una medida de buena calidad.

La fiabilidad importa para la predicción por una razón que será central en el diagnóstico (apartado 5.3): el error de medida atenúa las correlaciones. La correlación observada entre dos variables medidas con error es siempre menor, en valor absoluto, que la correlación entre sus puntuaciones verdaderas. Un predictor medido con error, por tanto, pierde capacidad predictiva por el mero hecho de la imperfección de la medida, antes incluso de cualquier otra consideración.

2.3 PUNTUACIONES DIRECTAS, PERCENTILES Y BAREMOS

La puntuación directa (PD) de una escala es la suma de las respuestas a sus ítems. Por sí sola es difícil de interpretar: saber que un candidato obtiene 42 puntos en tolerancia al riesgo no dice si es un valor alto o bajo. Para interpretarla se recurre a un *baremo*: una tabla, construida sobre una muestra normativa representativa, que traduce cada PD a una puntuación relativa. La más común es el *percentil* (Pc), que indica el porcentaje de la población normativa que obtiene una puntuación igual o inferior. Un percentil 95 significa que la persona supera al 95 % de la población de referencia.

Matemáticamente, el percentil es la función de distribución acumulada empírica de la población normativa evaluada en la PD del sujeto, multiplicada por cien. Esta observación tiene una consecuencia relevante para este trabajo: el percentil depende de la población

normativa elegida. Una misma PD se traduce en percentiles distintos según el baremo. Cuando la muestra de estudio difiere sistemáticamente de la población normativa —como ocurrirá aquí, donde los candidatos están preseleccionados—, los percentiles revelan ese desajuste, y su acumulación en valores altos es el síntoma del efecto techo que se analizará en el apartado 5.3.

2.4 VALIDEZ: EVIDENCIAS DE CONSTRUCTO Y DE CRITERIO

La validez es el concepto central de la psicometría moderna y el eje teórico de este trabajo. Según los Standards for Educational and Psychological Testing [7], la validez no es una propiedad dicotómica del test, sino el grado en que la evidencia disponible respalda las interpretaciones que se hacen de sus puntuaciones para un uso concreto. Se distinguen varias fuentes de evidencia; dos son decisivas aquí:

Validez de constructo (y convergente). Evidencia de que el test mide el constructo que dice medir. Se apoya en la estructura interna (que los ítems se organizan como la teoría predice) y en la relación con otras medidas del mismo constructo o de constructos afines (validez convergente). La BEPE exhibe esta evidencia de forma sobresaliente: estructura factorial replicable y correlaciones canónicas elevadas con los cinco grandes factores de personalidad y con otros instrumentos de emprendimiento [2].

Validez de criterio. Evidencia de que las puntuaciones predicen un criterio externo de interés —en este trabajo, una conducta o un resultado de desempeño—. Es la fuente de evidencia relevante cuando un test se usa para tomar decisiones de selección, y la más difícil de obtener.

La tesis que organiza este trabajo es que ambas fuentes de evidencia son lógicamente independientes: un test puede tener una validez de constructo excelente y, simultáneamente, una validez de criterio pobre para un uso y una población concretos. La calidad psicométrica de un instrumento no garantiza su utilidad predictiva. Por eso los Standards insisten en que la validez de criterio debe demostrarse **localmente**, para el criterio y la población de uso, y

no puede heredarse de la calidad general del test ni de su validez en otras poblaciones. La práctica de emplear un test bien construido en un proceso de selección sin haber establecido su validez de criterio local es, precisamente, el problema que este trabajo examina con datos.

Existe, además, una razón teórica de fondo que explica por qué un instrumento puede medir excelentemente un constructo y predecir mal una conducta concreta: la **compensación entre amplitud y fidelidad** de los rasgos [8], [9]. Un rasgo de banda ancha resume gran cantidad de información comportamental y permite predecir una amplia variedad de criterios, pero de forma difusa; un rasgo medido de forma restringida expresa con precisión una descripción comportamental específica y predice bien criterios estrechamente ligados a ella, a costa de su generalidad. La personalidad emprendedora, entendida como rasgo de banda relativamente ancha, está bien situada para describir el perfil psicológico general, pero no necesariamente para predecir un criterio tan específico, multicausal y dependiente del contexto como el éxito de un negocio de franquicia concreto. Esta tensión —y no un defecto del instrumento— es la que cabe esperar que se manifieste en los resultados, y es coherente con que la propia investigación sobre la BEPE encuentre una validez de constructo sobresaliente junto a una capacidad muy limitada para predecir la conducta emprendedora real (véase el Capítulo 6).

2.5 EL MODELO BIFACTOR COMO MODELO DE VARIABLES LATENTES

La estructura interna de la BEPE se describe mediante un modelo bifactor, que conviene presentar como el modelo de variables latentes que es, porque será la plantilla del generador de la simulación (apartado 5.4). En un modelo bifactor, la respuesta a cada ítem se explica por dos fuentes latentes simultáneas: un factor general G , común a todos los ítems de la batería (aquí interpretable como un constructo global de personalidad emprendedora), y un factor de grupo S_k , específico de la dimensión k a la que el ítem pertenece. Formalmente, la respuesta latente al ítem j de la dimensión k es:

$$x_j^* = \lambda_{G,j} G + \lambda_{k,j} S_k + \varepsilon_j$$

donde $\lambda_{G,j}$ y $\lambda_{k,j}$ son las cargas factoriales del ítem en el factor general y en su factor de grupo, G y los S_k son factores latentes independientes, y ε_j es el residuo. Las cargas cuantifican cuánto satura cada ítem en cada fuente. En la calibración publicada de la BEPE [2], las cargas en el factor general oscilan entre valores bajos y altos, siendo la dimensión de autonomía la más débilmente integrada en el factor general —un detalle que reaparecerá al interpretar la estructura de correlación de los datos. Este modelo justifica que las ocho dimensiones estén correlacionadas entre sí (comparten el factor general) sin ser redundantes (cada una tiene su factor específico), y permite generar datos sintéticos realistas a partir únicamente de las cargas, sin necesidad de las respuestas individuales.

2.6 EL CONSTRUCTO DE PERSONALIDAD EMPRENDEDORA Y SU EVOLUCIÓN

La investigación psicológica del emprendimiento ha seguido dos grandes vías. La primera recurre a los rasgos generales de personalidad, en particular el modelo de los cinco grandes factores, y estudia su relación con la actividad emprendedora [10], [11]. La segunda, que es la que da soporte a este trabajo, sostiene que para caracterizar al emprendedor son más útiles unos rasgos específicos vinculados directamente al espíritu emprendedor —autoeficacia, autonomía, innovación, propensión al riesgo y otros—, y aporta evidencia de que esos rasgos específicos añaden capacidad predictiva sobre los modelos generales [1], [12]. El meta-análisis de referencia de esta segunda línea [1] establece, además, los tamaños de efecto típicos de la relación entre rasgos y éxito emprendedor, que este trabajo utilizará como anclaje externo en el análisis de potencia.

Dentro de la perspectiva de rasgos específicos, el constructo de **personalidad emprendedora** no se concibe como un rasgo único sino como un conjunto de dimensiones que comparten un núcleo común. Esta concepción —varias facetas específicas integradas en un factor general— es exactamente la que el modelo bifactor del apartado «**El modelo bifactor como modelo de variables latentes**» formaliza, y la que la batería empleada en este trabajo operacionaliza. A este perfil de rasgos suele añadirse el grit, un constructo afín

procedente de la psicología de la motivación, que aporta el componente de perseverancia a largo plazo. Los instrumentos concretos que miden estos constructos en este Trabajo —la batería BEPE y la escala EGO— se describen en detalle en el Capítulo 4 (apartado «**Instrumentos y materiales**»), una vez presentado el contexto del estudio, para no anticipar su descripción operativa fuera de su lugar metodológico.

Capítulo 3. FUNDAMENTOS DE APRENDIZAJE

ESTADÍSTICO

Este capítulo formaliza el problema de predicción como un problema de aprendizaje supervisado y desarrolla las herramientas matemáticas que el trabajo emplea. El hilo conductor es la regresión logística, presentada no como una función de librería sino como el objeto matemático que es, y el énfasis recae en las particularidades del régimen de muestra pequeña, que es el régimen de este trabajo.

3.1 EL PROBLEMA DE APRENDIZAJE SUPERVISADO

Predecir el éxito a partir del perfil de un candidato es un problema de clasificación binaria supervisada. Se dispone de una muestra de pares (x_i, y_i) , $i = 1, \dots, n$, donde $x_i \in \mathbb{R}^p$ es el vector de variables predictoras del candidato e $y_i \in \{0,1\}$ indica el éxito, supuestamente extraídos de forma independiente de una distribución conjunta desconocida $P(x, y)$. El objetivo es hallar una función de decisión f que asigne a cada x una predicción, minimizando el **riesgo esperado** —el error promedio sobre la distribución verdadera—:

$$R(f) = \mathbb{E}_{(x,y) \sim P} [\ell(f(x), y)]$$

para una función de pérdida ℓ . El problema es que P es desconocida; solo se observa la muestra. Lo que sí puede calcularse es el **riesgo empírico**, el error promedio sobre los datos disponibles:

$$\hat{R}(f) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)$$

El principio de minimización del riesgo empírico consiste en elegir la f que minimiza $\hat{R}$. La cuestión central de la teoría del aprendizaje es bajo qué condiciones esa elección generaliza, es decir, cuándo un riesgo empírico bajo garantiza un riesgo esperado bajo. La respuesta

depende crucialmente del tamaño de la muestra y de la complejidad de la familia de funciones considerada, y es el núcleo del problema de este trabajo.

3.2 LA REGRESIÓN LOGÍSTICA COMO OBJETO MATEMÁTICO

La regresión logística modela la probabilidad de la clase positiva como una transformación de una combinación lineal de los predictores. Definiendo el logaritmo de la razón de probabilidades (log-odds) como una función lineal:

$$\log \frac{p(x)}{1-p(x)} = \beta_0 + \beta^\top x, \quad p(x) = \sigma(\beta_0 + \beta^\top x)$$

donde $\sigma(z) = \frac{1}{1+e^{-z}}$ es la función logística, cuya derivada satisface la identidad $\sigma'(z) = \sigma(z)(1-\sigma(z))$, que se usará en la derivación. Los coeficientes β se interpretan como logaritmos de razones de probabilidades (log-odds-ratios): un incremento unitario en la variable j multiplica las odds de éxito por e^{β_j} , lo que conecta el modelo con el lenguaje de la estadística aplicada y con la interpretación de los instrumentos psicométricos.

3.2.1 ESTIMACIÓN POR MÁXIMA VEROSIMILITUD

Sea una muestra de n observaciones independientes (x_i, y_i) con $y_i \in \{0,1\}$. Absorbiendo el término independiente en el vector de parámetros ($x_i \leftarrow (1, x_i), \beta \leftarrow (\beta_0, \beta)$), cada respuesta sigue una distribución de Bernoulli con probabilidad $p_i = \sigma(\beta^\top x_i)$. La función de verosimilitud es el producto de las probabilidades individuales:

$$L(\beta) = \prod_{i=1}^n p_i^{y_i} (1-p_i)^{1-y_i}$$

y, tomando logaritmos, la log-verosimilitud que se desea maximizar es:

$$\ell(\beta) = \sum_{i=1}^n [y_i \log p_i + (1-y_i) \log(1-p_i)] = \sum_{i=1}^n [y_i \beta^\top x_i - \log(1 + e^{\beta^\top x_i})]$$

La segunda forma, obtenida sustituyendo $p_i = \sigma(\beta^\top x_i)$ y simplificando, es más cómoda para derivar. Maximizar $\ell(\beta)$ equivale a minimizar la función de pérdida de entropía cruzada (log-loss), $J(\beta) = -\ell(\beta)$, que es la formulación habitual en aprendizaje automático.

3.2.2 GRADIENTE (ECUACIONES DE SCORE) Y MATRIZ HESSIANA

El gradiente de la log-verosimilitud respecto a β —el vector de ecuaciones de score— se obtiene derivando y usando la identidad de la derivada de σ . El resultado tiene una forma notablemente simple:

$$\nabla \ell(\beta) = \sum_{i=1}^n (y_i - p_i) x_i = X^\top (y - p)$$

donde X es la matriz de diseño $n \times (p + 1)$, y el vector de respuestas y y $p = (p_1, \dots, p_n)^\top$ el vector de probabilidades ajustadas. Las ecuaciones de score $\nabla \ell(\beta) = 0$ no son lineales en β (porque p depende de β a través de σ) y, por tanto, no tienen solución cerrada. La matriz hessiana, derivando de nuevo, es

$$H(\beta) = \nabla^2 \ell(\beta) = - \sum_{i=1}^n p_i (1 - p_i) x_i x_i^\top = -X^\top W X$$

con $W = \text{diag}(p_1(1 - p_1), \dots, p_n(1 - p_n))$ una matriz diagonal de pesos, positivos porque $p_i \in (0,1)$. Para cualquier vector $v \neq 0$ se cumple $v^\top (X^\top W X) v = \sum_i w_i (x_i^\top v)^2 \geq 0$, de modo que $X^\top W X$ es semidefinida positiva y, en consecuencia, **$H(\beta)$ es semidefinida negativa**. Esto demuestra que $\ell(\beta)$ es cóncava (estrictamente cóncava si X tiene rango completo por columnas), por lo que el problema de máxima verosimilitud es un problema de optimización convexa: todo máximo local es global y, cuando existe, es único.

3.2.3 EL ALGORITMO DE NEWTON-RAPHSON E IRLS

Al carecer de solución cerrada, β se estima iterativamente. El método de Newton-Raphson actualiza la estimación mediante

$$\beta^{(t+1)} = \beta^{(t)} - H(\beta^{(t)})^{-1} \nabla \ell(\beta^{(t)}) = \beta^{(t)} + (X^\top W X)^{-1} X^\top (y - p)$$

Reorganizando esta expresión se obtiene una forma equivalente y reveladora. Definiendo la *variable de trabajo* (working response) $z^{(t)} = X\beta^{(t)} + W^{-1}(y - p)$, la actualización se escribe como:

$$\beta^{(t+1)} = (X^T W X)^{-1} X^T W z^{(t)}$$

que es exactamente la solución de un problema de **mínimos cuadrados ponderados** sobre z con pesos W . Por ello el algoritmo se denomina mínimos cuadrados reponderados iterativamente (IRLS, *iteratively reweighted least squares*): en cada paso se resuelve una regresión lineal ponderada, se recalculan p y W con los nuevos coeficientes, y se repite hasta converger. La convergencia es típicamente cuadrática cerca del óptimo gracias a la concavidad.

3.2.4 LA FRONTERA DE DECISIÓN

La regla de clasificación asigna la clase positiva cuando $p(x) \geq 0,5$, lo que equivale a $\beta^T x \geq 0$. La frontera de decisión $\{x: \beta^T x = 0\}$ es, por tanto, un hiperplano en el espacio de predictores: la regresión logística es un clasificador lineal. Esta linealidad motiva incluir en el trabajo un modelo no lineal de contraste (Capítulo 5): si tanto el clasificador lineal como uno flexible fracasan por igual, se descarta que la señal predictiva resida en relaciones no lineales que el modelo lineal no podría capturar.

Finalmente, conviene observar que la regresión logística es la red neuronal más simple posible: una única unidad con función de activación sigmoide y pérdida de entropía cruzada. Esta lectura sitúa el modelo dentro del paradigma del aprendizaje profundo y permite argumentar por qué, en el régimen de datos de este trabajo (n pequeño, p moderado), una arquitectura de una sola neurona regularizada no es una simplificación sino la elección que la teoría de la complejidad muestral prescribe frente a redes sobreparametrizadas.

3.3 EL RÉGIMEN DE MUESTRA PEQUEÑA: SEPARACIÓN Y LA NECESIDAD DE REGULARIZAR

En muestras pequeñas con varios predictores, la estimación por máxima verosimilitud presenta un problema que conecta directamente con el resultado empírico de este trabajo. Cuando existe un hiperplano que separa perfectamente las dos clases —situación tanto más probable cuanto menor es n y mayor es p —, la verosimilitud no alcanza un máximo finito: los coeficientes que la maximizan divergen a infinito. Es el fenómeno de **separación** [13]. Su interpretación es elocuente: el modelo se ajusta tan perfectamente a la muestra que sus parámetros se vuelven infinitos e inestables. La separación es la manifestación matemática extrema del sobreajuste, y su aparición es una señal de que la muestra es insuficiente para la complejidad del modelo.

La solución es la **regularización**: añadir al objetivo un término que penalice los coeficientes grandes, acotando la solución. La penalización elastic-net combina las normas L1 y L2:

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \left[-\ell(\beta) + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right) \right]$$

donde $\lambda \geq 0$ controla la intensidad de la penalización y $\alpha \in [0,1]$ reparte entre la componente L1 (lasso) y la L2 (ridge). La componente L2 contrae los coeficientes hacia cero de forma suave y estabiliza la estimación; la componente L1, por la geometría de la bola que define (con vértices sobre los ejes), induce soluciones dispersas, anulando coeficientes y realizando así selección de variables [14], [15]. La regularización es, en esencia, un mecanismo para introducir sesgo de forma controlada a cambio de reducir la varianza del estimador, lo que enlaza con la sección siguiente.

3.4 SESGO, VARIANZA Y COMPLEJIDAD MUESTRAL

El error de generalización de un modelo puede descomponerse en tres términos: un sesgo al cuadrado (error sistemático por la incapacidad del modelo para representar la relación verdadera), una varianza (sensibilidad del modelo a la muestra concreta) y un error

irreducible (el ruido inherente). Modelos muy flexibles tienen sesgo bajo pero varianza alta —ajustan bien en promedio pero son inestables—, mientras que modelos rígidos o muy regularizados sacrifican sesgo para ganar estabilidad. El compromiso óptimo depende del tamaño de la muestra: con pocos datos, la varianza domina, y conviene desplazarse hacia modelos más simples o más regularizados.

La teoría del aprendizaje estadístico formaliza esta intuición mediante cotas de generalización. Resultados basados en la dimensión de Vapnik-Chervonenkis o en la complejidad de Rademacher acotan, con alta probabilidad, la diferencia entre el riesgo esperado y el riesgo empírico por un término que decrece con n y crece con la complejidad de la familia de funciones [16]–[18]. La lectura para este trabajo es directa: con n pequeño y p moderado, un modelo flexible puede alcanzar un riesgo empírico engañosamente bajo —incluso nulo, en el caso de la separación— mientras su riesgo esperado permanece alto. La distancia entre ambos es precisamente lo que el rendimiento por resustitución oculta y lo que la validación honesta revela.

3.5 EVALUACIÓN HONESTA DEL RENDIMIENTO

Estimar el rendimiento de un modelo sobre los mismos datos con los que se ajustó (resustitución) produce una estimación optimista del rendimiento futuro, tanto más cuanto mayor es el sobreajuste. La evaluación honesta requiere estimar el error sobre datos no usados en el ajuste. Con muestras pequeñas, apartar un conjunto de test reduciría aún más los datos de entrenamiento; se emplea por ello la **validación cruzada**, que reutiliza eficientemente la muestra. En su forma de dejar-uno-fuera (LOO), se ajusta el modelo n veces, cada una omitiendo una observación que se usa para evaluar. Cuando el modelo tiene hiperparámetros (como λ y α en elastic-net), su selección debe hacerse **dentro** del procedimiento de validación, mediante validación cruzada anidada, para no contaminar la estimación del error con información del conjunto de evaluación [19], [20].

Como métrica de rendimiento para clasificación con clases desbalanceadas se emplea el área bajo la curva ROC (AUC), que mide la probabilidad de que el modelo asigne mayor

puntuación a un caso positivo que a uno negativo elegidos al azar; un AUC de 0,5 corresponde al azar. La significación del AUC se evalúa mediante un **test de permutación**: se reordenan aleatoriamente las etiquetas muchas veces y se reejecuta el procedimiento completo, construyendo la distribución del AUC bajo la hipótesis nula de ausencia de relación entre predictores y criterio; el AUC observado se compara con esa distribución [21]. Se prefiere la permutación al intervalo paramétrico de DeLong porque este último supone independencia entre las predicciones, supuesto que la validación cruzada viola al compartir datos entre pliegues.

3.6 RESTRICCIÓN DE RANGO

Cuando la muestra disponible no es la población general sino un subconjunto preseleccionado, la varianza de los predictores se reduce, y con ella la correlación observada con el criterio. Es la **restricción de rango**, una amenaza clásica a la validez en contextos de selección [22], [23]. El efecto es de atenuación: la correlación medida en el grupo restringido subestima sistemáticamente la correlación que existiría en la población completa. Su corrección, en el caso más simple (restricción directa sobre el predictor, caso II de Thorndike), estima la correlación no restringida a partir de la observada y de la razón $U = S/s$ entre la desviación típica de la población (S) y la del grupo restringido (s):

$$\hat{\rho} = \frac{U r}{\sqrt{1 + r^2(U^2 - 1)}}$$

Este trabajo aplica la corrección usando como desviaciones típicas no restringidas las de las normas poblacionales publicadas de la BEPE, lo que permite estimar en qué medida la preselección, por sí sola, atenúa la validez. La restricción de rango se manifiesta empíricamente como el efecto techo —la acumulación de puntuaciones en valores altos— que se documenta en el apartado 5.1.

3.7 POTENCIA ESTADÍSTICA Y DETECTABILIDAD

Un contraste de hipótesis liga cuatro cantidades: el tamaño del efecto verdadero, el tamaño muestral n , el nivel de significación α y la potencia $1 - \beta$ (la probabilidad de detectar un efecto que existe). Fijadas tres, la cuarta queda determinada [24]. De esta relación se obtienen dos lecturas. La **retrospectiva** fija n , α y una potencia objetivo (convencionalmente 0,80) y despeja el **efecto mínimo detectable (MDE)**: el menor efecto que la muestra puede detectar con fiabilidad. La **prospectiva** fija el efecto que se desea poder detectar y despeja el n necesario. El tamaño de efecto de esta segunda cuenta no puede provenir de la propia muestra —los efectos estimados en muestras pequeñas están inflados [25]—, sino de evidencia externa.

Es esencial distinguir el MDE de la desacreditada *potencia observada* o post-hoc, que calcula la potencia usando el efecto observado en la propia muestra y que no es más que una transformación monótona del valor p , sin aportar información nueva [26]. El MDE fija la potencia objetivo y despeja el efecto: es lógica prospectiva aplicada al n actual, y es legítima.

El puente entre la potencia clásica y la métrica de clasificación de este trabajo es, bajo el supuesto de normalidad binormal, la relación $AUC = \Phi\left(\frac{d}{\sqrt{2}}\right)$, que traduce un tamaño de efecto d (diferencia estandarizada de medias entre grupos) en el AUC esperado. Ahora bien, las fórmulas cerradas de potencia describen contrastes simples; el procedimiento real de este trabajo —clasificación regularizada con validación cruzada, predictores correlacionados, techo y desbalanceo— no admite fórmula. Por ello la potencia del procedimiento completo se estima por simulación Monte Carlo (apartado 5.4), que mide la capacidad de detección del pipeline real generando datos bajo un efecto verdadero conocido.

3.8 INTERPRETABILIDAD Y USO RESPONSABLE DE LOS MODELOS

El uso de modelos de aprendizaje automático en decisiones de alto impacto humano —como la selección de personas— exige atender a su **interpretabilidad**: la capacidad de comprender por qué un modelo produce una determinada salida. Frente a los modelos «caja

negra», la literatura de *interpretable machine learning* propone métodos para hacer inteligible la contribución de cada variable a la predicción, y subraya que en contextos sensibles la transparencia es un requisito y no un lujo, para evitar decisiones opacas o difícilmente justificables [27], [28]. La regresión logística empleada en este trabajo es, en este sentido, un modelo intrínsecamente interpretable: sus coeficientes son log-odds-ratios directamente legibles, lo que la hace preferible en aplicaciones donde la justificabilidad importa, frente a modelos más opacos de rendimiento comparable.

Este trabajo plantea, además, un matiz que la literatura de interpretabilidad rara vez aborda y que su resultado pone de relieve. Las técnicas de interpretabilidad —importancia de variables, contribuciones individuales, análisis de coeficientes— suelen presentarse como un medio para *explicar* las decisiones de un modelo que se da por válido. Pero cuando un modelo carece de validez predictiva, la interpretabilidad cambia de función: deja de justificar decisiones y pasa a ser una **herramienta de diagnóstico**. En tal caso, el análisis de la contribución de las variables no revela «qué importa para predecir», sino que evidencia que ninguna variable contribuye de forma estable —que los pesos del modelo son artefactos de la muestra, no relaciones reproducibles—. Como se verá, la regularización elástica ofrece una manifestación nítida de esta idea: al penalizar, contrae los coeficientes hacia la anulación, de modo que el propio mecanismo de selección de variables concluye que ningún predictor merece peso. Interpretabilidad y honestidad metodológica se vuelven, así, la misma cosa: el uso responsable de la IA en selección consiste, ante todo, en no desplegar como apoyo a la decisión un modelo cuya interpretación revela que no contiene señal.

Capítulo 4. DATOS Y METODOLOGÍA

4.1 INSTRUMENTOS Y MATERIALES

La recogida de datos se basó en tres instrumentos: la batería BEPE para la evaluación de la personalidad emprendedora, la escala EGO para la evaluación del grit, y un cuestionario sociodemográfico diseñado ad hoc para este estudio. Se describen a continuación, dado que la naturaleza y las propiedades de los instrumentos condicionan tanto el análisis como la interpretación de los resultados.

4.1.1 LA BATERÍA PARA LA EVALUACIÓN DE LA PERSONALIDAD EMPRENDEDORA (BEPE)

La BEPE es un cuestionario de autoinforme para la evaluación de la personalidad emprendedora en población adulta, desarrollado por el equipo de la Universidad de Oviedo (Cuesta, Suárez-Álvarez, Lozano, Postigo, García-Cueto y Muñiz) y publicado comercialmente por Hogrefe-TEA Ediciones. Es el instrumento de referencia en español para este constructo, y se sustenta en un amplio programa de validación recogido en la bibliografía especializada [2], [29]–[32], que incluye versiones para jóvenes, una forma reducida y versiones adaptativas computarizadas [33].

La batería evalúa **ocho dimensiones sustantivas** de la personalidad emprendedora, cuyas definiciones, tomadas de la documentación del instrumento, son las siguientes:

Autoeficacia (AE). Grado de convicción sobre la propia capacidad para organizar y ejecutar acciones de forma eficaz, y persistencia ante los obstáculos hasta alcanzar los resultados deseados.

Autonomía (AU). Medida en que la persona busca su libertad individual y el control sobre las tareas que realiza; la autonomía es una de las principales razones para emprender.

Innovación (IN). Búsqueda continua de nuevas formas de acción e interés por nuevas ideas y soluciones.

Locus de control interno (LI). Grado en que la persona considera que las consecuencias de su comportamiento dependen de sí misma (frente a razones externas fuera de su control).

Motivación de logro (ML). Esfuerzo por trabajar en la consecución de metas personales y profesionales, con deseo de alcanzar —y mejorar— estándares de excelencia.

Optimismo (OP). Tendencia a creer que sucederán más eventos positivos que negativos y que las expectativas se cumplirán en el futuro.

Tolerancia al estrés (TE). Capacidad de aplicar estrategias de afrontamiento adecuadas y seguir funcionando bien bajo niveles altos de tensión.

Toma de riesgos (TR). Capacidad de asumir ciertos niveles de riesgo para alcanzar una meta propuesta.

Además de las ocho dimensiones, el instrumento proporciona un índice general, **Emprendimiento Global (EMP)**, que resume el perfil en una puntuación de conjunto, e incorpora una **escala de Deseabilidad Social (DS)**: una escala de control que valora hasta qué punto la persona ha tratado de ofrecer una imagen marcadamente positiva de sí misma. Según la documentación del test, cuando la puntuación en DS es alta o muy alta es probable que los resultados estén inflados y que las escalas reflejen un nivel superior al real. Los ítems siguen un formato Likert de cinco categorías (de «totalmente en desacuerdo» a «totalmente de acuerdo»).

La interpretación de las puntuaciones es normativa: cada puntuación directa (PD) se transforma en un percentil (Pc) respecto a un baremo, y el manual define cinco bandas interpretativas —muy bajo (Pc 1–2), bajo (3–15), medio (16–84), alto (85–97) y muy alto (98–99)—. En cuanto a sus propiedades psicométricas, la versión adulta presenta fiabilidades por escala entre 0,81 y 0,89 (alfa) y una estructura interna mejor descrita por un modelo bifactor con un factor general y ocho factores de grupo [2], tal como se expuso en el

Capítulo 2 (apartados «**El modelo bifactor como modelo de variables latentes**» y «**El constructo de personalidad emprendedora y su evolución**»). Estas cargas factoriales publicadas son, además, la base del generador de la simulación del apartado 5.4.

Una observación metodológica de primer orden. La escala de Deseabilidad Social (DS) es especialmente pertinente en este estudio porque la BEPE se administró en un contexto de **selección de alto riesgo**: los candidatos a franquiciado tienen un incentivo directo para responder de forma socialmente deseable y proyectar un perfil emprendedor favorable («faking good»), un sesgo bien documentado en los autoinformes de personalidad usados para decisiones de selección, donde su influencia es especialmente evidente [34]. La propia tesis doctoral del programa de la BEPE señala la deseabilidad social como un sesgo de respuesta a vigilar en los contextos donde se evalúa la personalidad emprendedora —entidades que otorgan subvenciones, empresas de selección de personal— precisamente como el de este trabajo [4]. Como se detalla en el apartado «**La muestra: las franquicias y los candidatos**», el conjunto de datos facilitado no incluye la escala DS, lo que impide controlar este sesgo y, como se argumentará en los Capítulos 5 y 6, constituye una explicación plausible —complementaria a la restricción de rango— del efecto techo observado en las puntuaciones. La ausencia de DS es, por tanto, una limitación relevante y un elemento del diagnóstico, no un detalle accesorio.

En este trabajo se administró la versión de la BEPE para población adulta, y las puntuaciones directas de cada dimensión se transformaron a percentiles mediante el baremo de población general (varones y mujeres combinados). La batería incluye, además de las ocho dimensiones sustantivas y el índice de Emprendimiento Global, una escala de Deseabilidad Social, que figura en los informes individuales y cuya pertinencia se comenta en el apartado 5.1.2.

4.1.2 LA ESCALA GRIT DE OVIEDO (EGO)

La escala EGO operacionaliza el grit, definido como la combinación de perseverancia del esfuerzo y consistencia del interés en la consecución de objetivos a largo plazo [3]. En la misma línea de investigación que la BEPE, el grit se ha vinculado con la personalidad

empresadora, la responsabilidad y el autocontrol [35]. Sus puntuaciones se sitúan en una escala de 1 a 5. Conceptualmente, el grit solapa de manera notable con la dimensión de motivación de logro de la BEPE, lo que plantea la cuestión empírica de si aporta validez incremental o resulta redundante, cuestión que el trabajo examina explícitamente (objetivo C5).

4.1.3 EL CUESTIONARIO SOCIODEMOGRÁFICO AD HOC

Para caracterizar a los candidatos y disponer de un bloque de predictores alternativo al psicométrico, se elaboró un cuestionario sociodemográfico específico para este estudio. Este instrumento se inscribe en la tradición de los datos biográficos («biodata») en selección de personal, cuya capacidad predictiva del desempeño compite, según una extensa literatura, con la de los tests de personalidad. El cuestionario recoge las siguientes variables: edad, género, nivel educativo, años de experiencia (profesional/en el sector), experiencia previa de liderazgo de equipos, estado civil y número de hijos dependientes.

Las variables sociodemográficas y la escala de grit (EGO) se recogieron mediante un cuestionario propio diseñado en la plataforma Tally y cumplimentado por los propios participantes. El cuestionario recoge edad, género, nivel educativo (con categorías que abarcan desde bachillerato y formación técnica hasta grado y posgrado), años de experiencia por tramos, experiencia previa de liderazgo de equipos, estado civil e hijos dependientes.

4.2 LA MUESTRA: LAS FRANQUICIAS Y LOS CANDIDATOS

La muestra procede de los procesos reales de selección de franquiciados de dos enseñanzas españolas consolidadas que operan en segmentos contiguos de la industria del bienestar (wellness):

Japanese Spa (identificada con la enseña Japanese Head Spa). Red de franquicias del sector del bienestar y la estética, fundada en Málaga a finales de 2023, pionera en Europa en el concepto de «head spa» —un ritual sensorial premium centrado en la salud del cuero cabelludo y la relajación, de inspiración japonesa—. Su expansión ha sido muy rápida (del

orden de medio centenar de centros en varios países en poco más de un año) y fue reconocida como franquicia emergente del año en 2024. El perfil de franquiciado es el de pequeños inversores y emprendedores, con una inversión inicial moderada (en torno a 40.000 €).

Brooklyn Fitness (identificada con la enseña Brooklyn Fitboxing). Red de franquicias del sector del fitness, fundada en Madrid en 2014, especializada en boxeo sin contacto combinado con entrenamiento de alta intensidad y gamificación (sesiones de 47 minutos). Es una de las cadenas de gimnasios boutique en franquicia más consolidadas, con varios cientos de clubes en una decena de países. El perfil de franquiciado es también de inversores emprendedores, con frecuencia propietarios de más de una unidad, y una inversión inicial más elevada (del orden de 100.000–200.000 €).

Las dos enseñas comparten rasgos relevantes para el estudio —ambas son redes de franquicia españolas del amplio sector del bienestar que reclutan a emprendedores-inversores— y difieren en otros: el subsector (estética/spa frente a fitness), la madurez de la red (fundada en 2023 frente a 2014) y la intensidad de capital. Esta combinación es metodológicamente significativa por dos motivos. Primero, el perfil de éxito de un franquiciado y los factores que lo determinan podrían no ser los mismos en un spa urbano que en un gimnasio, lo que justifica que el análisis contemple la enseña como covariable y que se realice un análisis diferenciado por marca como comprobación de robustez (Capítulo 5). Segundo, y de forma más profunda, la población de franquiciados es por naturaleza una muestra emprendedora preseleccionada —personas que ya han decidido invertir, han sido aceptadas por la enseña y han superado sus filtros—, lo que motiva directamente el argumento de restricción de rango del apartado 5.3: no se evalúa a la población general, sino a un subconjunto ya filtrado hacia el perfil emprendedor.

La muestra consta de 45 candidatos evaluados, de los cuales 41 disponen del criterio de éxito conocido. La distribución por enseña es de 23 candidatos de Brooklyn Fitness y 18 de Japanese Spa; la distribución del criterio es de 26 casos con éxito y 15 sin éxito, lo que arroja una tasa base de éxito del 63,4 %. Los cuatro casos sin criterio conocido se tratan según se indica en el plan de análisis.

4.3 VARIABLES

Las variables empleadas en el análisis se agrupan en tres familias:

Psicométricas. Las ocho dimensiones de la BEPE (AE, AU, IN, LI, ML, OP, TE, TR) y la puntuación global de emprendimiento (EMP), que no es una variable independiente sino el agregado de las ocho dimensiones anteriores, disponibles en puntuación directa y en percentil; y la puntuación de grit de la escala EGO. Nota: la escala de Deseabilidad Social (DS) del instrumento no está disponible en el conjunto de datos (véase 4.1.1).

Sociodemográficas. Edad, género, nivel educativo, años de experiencia, experiencia previa de liderazgo de equipos, estado civil y número de hijos dependientes, recogidas mediante el cuestionario ad hoc.

Criterio. Un indicador binario de éxito del franquiciado (variable dependiente).

4.4 OPERACIONALIZACIÓN DEL CRITERIO DE ÉXITO

La definición operativa del criterio es un aspecto crítico, dado que toda la validez de criterio depende de qué mide exactamente la variable dependiente. En este trabajo el criterio de éxito no se definió de forma unificada para toda la muestra: cada central fijó internamente su propio criterio, atendiendo a las particularidades de su modelo de negocio. Esta decisión refleja la práctica real de las enseñanzas, pero introduce una heterogeneidad entre ellas que se declara explícitamente y cuyas implicaciones para la validez se analizan en el apartado «Amenazas a la validez de este trabajo» (Cap. 6).

Los criterios concretos aplicados por cada enseñanza (los hitos, umbrales y procedimientos internos con los que cada central determina si un franquiciado ha tenido éxito) no se reproducen en este documento por acuerdo de confidencialidad con las centrales. A efectos del análisis, cada enseñanza proporcionó la etiqueta resultante como un indicador binario de éxito / no-éxito.

Esta operacionalización tiene la virtud de basarse, en su mayor parte, en hechos objetivos y registrables. No obstante, presenta dos características que condicionan la interpretación de los resultados y que se examinan como amenazas a la validez en el apartado «Amenazas a la validez de este trabajo» (Cap. 6): la falta de homogeneidad del criterio entre las dos enseñanzas y la presencia, en una de ellas, de un componente parcialmente subjetivo.

Una precisión sobre el diseño temporal del estudio es imprescindible. La evaluación psicométrica (BEPE y grit) y el cuestionario sociodemográfico se administraron durante la fase de realización de este trabajo, cuando los participantes ya eran franquiciados y su desenlace era conocido. El diseño es, por tanto, transversal y retrospectivo, no prospectivo: los predictores no se midieron antes del criterio, sino simultáneamente a su conocimiento. Esta característica, que se examina en el apartado «Amenazas a la validez de este trabajo» (Cap. 6), refuerza la decisión de plantear el trabajo como un estudio de asociación y de viabilidad y no como una predicción en sentido causal estricto.

4.5 CONSIDERACIONES ÉTICAS Y PROTECCIÓN DE DATOS

Los datos contienen información personal sensible (perfil de personalidad, situación familiar y desempeño profesional de personas identificables). El tratamiento se realiza sobre una versión seudonimizada del fichero, de la que se han eliminado los identificadores directos (direcciones de correo electrónico) y en la que el identificador de caso se ha sustituido por un código arbitrario no reidentificable. Se cumple así el principio de minimización del Reglamento General de Protección de Datos. Conviene recordar que la seudonimización no

equivale a anonimización: el conjunto sigue siendo dato personal, por lo que no se difunde la tabla de correspondencia y los datos se publican únicamente en su forma seudonimizada, con acceso restringido al tribunal.

4.6 VERIFICACIONES DE INTEGRIDAD

Antes del análisis se comprobó la integridad del fichero: ausencia de registros duplicados, coherencia de la puntuación global de la BEPE con la suma de las ocho dimensiones, y monotonía de la relación entre puntuaciones directas y percentiles dentro de cada dimensión.

Las verificaciones de integridad confirmaron la ausencia de registros duplicados y la coherencia de la puntuación global de emprendimiento con la suma de las ocho subescalas, así como la correcta correspondencia entre puntuaciones directas y percentiles.

4.7 PLAN DE ANÁLISIS PRERREGISTRADO

Para evitar la flexibilidad analítica que invalidaría las conclusiones, el plan de análisis se fijó antes de ejecutar los análisis (se incluye en el repositorio, **Anexo C**). Comprende cuatro fases, que corresponden a los apartados 5.1 a 5.4:

Análisis exploratorio y relación univariante de cada variable —psicométrica y sociodemográfica— con el criterio: correlaciones punto-biserials con intervalos de confianza por la transformación z de Fisher y diferencias de medias estandarizadas (d de Cohen), con una verificación de robustez mediante inversión de etiquetas del criterio, global y por enseña.

Modelización predictiva comparada: modelos jerárquicos (solo variables sociodemográficas; solo psicométricas; ambas combinadas) con regresión logística regularizada (elastic-net, con hiperparámetros seleccionados en una rejilla interna), un modelo no lineal de contraste (por ejemplo, gradient boosting), validación cruzada anidada dejando-uno-fuera, AUC validado, test de permutación de al menos 1.000 réplicas, y comparación con el clasificador trivial basado en la tasa base.

Diagnóstico de mecanismos: documentación del efecto techo frente a las normas poblacionales, corrección de Thorndike para estimar la validez desatenuada, cálculo del efecto mínimo detectable y del tamaño muestral requerido para efectos externos realistas.

Estudio de simulación Monte Carlo: generador calibrado sobre los parámetros bifactor publicados de la BEPE, con el efecto verdadero situado en el factor latente y la preselección modelada explícitamente; estimación de la potencia del procedimiento completo, curva de aprendizaje y mapa de detectabilidad, con validación del simulador y análisis de sensibilidad.

El análisis se realizó en Python (bibliotecas scikit-learn, statsmodels y SciPy), con semillas aleatorias fijadas para garantizar la reproducibilidad. El código se recoge en el Anexo A.

Capítulo 5. RESULTADOS

5.1 ANÁLISIS EXPLORATORIO

Este capítulo describe la muestra y examina la asociación univariante de cada variable con el éxito. Su función es doble: caracterizar los datos (en particular, documentar el efecto techo que el apartado 5.3 retomará) y ofrecer una primera respuesta a la pregunta de si existe alguna señal predictor-criterio antes de pasar a la modelización multivariante.

5.1.1 DESCRIPTIVOS Y ESTRUCTURA DE LOS PREDICTORES

La Tabla 1 recoge los estadísticos descriptivos de las variables psicométricas y sociodemográficas. En el Anexo B se recoge la matriz de intercorrelaciones entre las dimensiones de la BEPE, cuya estructura debe interpretarse a la luz del modelo bifactor (Cap. 2, apartado «El modelo bifactor como modelo de variables latentes»): una correlación media moderada entre dimensiones, compatible con un factor general común.

Tabla 1. Estadísticos descriptivos de las variables psicométricas y sociodemográficas (media, desviación típica, mínimo y máximo).

Variable	Media	DT	Mín.	Máx.
Autoeficacia (AE)	42,1	5,34	27	50
Autonomía (AU)	40,4	5,03	29	50
Innovación (IN)	43,8	4,90	32	50
Locus interno (LI)	42,3	6,32	21	50
Motivación de logro (ML)	43,3	4,94	33	50
Optimismo (OP)	43,5	5,66	25	50

Tolerancia al estrés (TE)	35,3	5,70	22	47
Toma de riesgos (TR)	43,0	5,01	29	50
Emprendimiento global (EMP)	333,8	32,52	236	388
Grit (EGO)	4,44	0,48	3,2	5
Edad (años)	41,0	9,25	23	61

5.1.2 EFECTO TECHO: CONTRASTE CON LAS NORMAS POBLACIONALES

Dado que la muestra está preseleccionada, se examina el grado de saturación de las puntuaciones. La Figura 1 muestra, para cada dimensión, el porcentaje de la muestra que supera el percentil 95 de la población normativa —donde por construcción cabría esperar un 5 % [2].




Figura 1. Saturación de las dimensiones BEPE frente a las normas poblacionales: porcentaje de la muestra en percentiles altos (efecto techo).

La interpretación de este efecto techo admite **dos lecturas no excluyentes**, que conviene plantear desde aquí. La primera es la restricción de rango por preselección (Cap. 3, apartado

«**Restricción de rango**»): los candidatos que llegan a ser evaluados ya han superado filtros previos, de modo que constituyen una submuestra sesgada hacia perfiles altos. La segunda es la **deseabilidad social**: al tratarse de un contexto de selección, los candidatos tienen un incentivo para ofrecer una imagen favorable, lo que desplazaría artificialmente las puntuaciones hacia arriba (Cap. 4, apartado «**La Batería para la Evaluación de la Personalidad Emprendedora (BEPE)**»). La BEPE dispone de una escala (DS) precisamente para detectar este sesgo, pero no está disponible en el conjunto de datos, por lo que no es posible cuantificar directamente su contribución. Ambos mecanismos — preselección real y respuesta socialmente deseable— producen el mismo síntoma (compresión de la varianza en la parte alta) y ambos atenúan la capacidad predictiva; distinguirlos requeriría la escala DS o un diseño con evaluación previa a la selección.

5.1.3 RELACIÓN UNIVARIANTE CON EL CRITERIO

La Tabla 2 presenta la correlación punto-biserial de cada variable con el éxito, con su intervalo de confianza al 95 % y el tamaño de efecto d de Cohen asociado.

Tabla 2. Correlaciones punto-biserials de cada variable con el criterio, con intervalo de confianza al 95 %, valor p y tamaño del efecto (d de Cohen).

Variable	r punto-biserial	IC 95 %	p	d de Cohen
Tolerancia al estrés (TE)	-0,218	-0,493 ; 0,096	0,171	-0,453
Toma de riesgos (TR)	-0,160	-0,446 ; 0,155	0,318	-0,328
Optimismo (OP)	-0,154	-0,441 ; 0,161	0,335	-0,317
Motivación de logro (ML)	-0,113	-0,406 ; 0,202	0,482	-0,230
Autoeficacia (AE)	-0,107	-0,402 ; 0,207	0,505	-0,218
Innovación (IN)	-0,097	-0,393 ; 0,217	0,545	-0,198
Locus interno (LI)	0,066	-0,247 ; 0,366	0,682	0,134

Autonomía (AU)	0,047	-0,265 ; 0,349	0,771	0,095
Grit (EGO)	0,027	-0,283 ; 0,332	0,865	0,056
Edad (años)	0,202	-0,113 ; 0,480	0,206	0,412

5.1.4 VERIFICACIÓN DE ROBUSTEZ: INVERSIÓN DE ETIQUETAS

Para descartar que un eventual resultado nulo se deba a un error de codificación del criterio (un intercambio de las etiquetas de éxito y fracaso), se repite el análisis con el criterio invertido, de forma global y separadamente por enseña. Conviene anticipar el argumento: invertir las etiquetas cambia el signo de las correlaciones pero conserva su magnitud y, al reajustar cualquier modelo, su capacidad discriminante es invariante; por tanto, si las etiquetas estuvieran intercambiadas, la inversión revelaría una relación fuerte. Asimismo, una inversión que afectara a una sola enseña se manifestaría como signos opuestos entre las dos.

Esta verificación es especialmente pertinente en este trabajo por la forma en que se construye el criterio (Cap. 4, apartado «Operacionalización del criterio de éxito»): la etiqueta cruda del estudio marca con el valor 1 el *evento de fracaso* (impago o cierre), mientras que la variable de análisis se denomina «éxito». Si en la transformación de una a otra se hubiera mantenido la dirección de la etiqueta cruda en lugar de invertirla, el signo de todas las asociaciones quedaría intercambiado. La verificación de inversión, junto con la confirmación de la convención de codificación pedida en el apartado «Operacionalización del criterio de éxito» (Cap. 4), cierra esta cuestión de forma definitiva.

La verificación de inversión de etiquetas confirma que la codificación del criterio es correcta: al invertir la etiqueta, las correlaciones con el criterio cambian de signo como es esperable y no mejoran ni en el conjunto agrupado ni por enseña, lo que descarta que el resultado nulo se deba a un error de codificación de la variable dependiente.

5.2 MODELIZACIÓN PREDICTIVA

Este capítulo construye y evalúa, con validación honesta, modelos de predicción del éxito. El diseño responde a dos preguntas: si algún modelo predice por encima del azar, y si el bloque psicométrico aporta capacidad predictiva sobre el sociodemográfico (validez incremental).

5.2.1 DISEÑO DE LA COMPARACIÓN

Se ajustan tres conjuntos de predictores de forma jerárquica —solo sociodemográficas, solo psicométricas, y ambas combinadas— con dos familias de modelos: regresión logística regularizada (elastic-net) como modelo base interpretable, y un modelo no lineal (gradient boosting) como contraste para descartar que la señal sea de naturaleza no lineal. Todos los modelos se evalúan con validación cruzada anidada dejando-uno-fuera, reportando el AUC validado junto al de resustitución, y se comparan con el clasificador trivial que predice siempre la clase mayoritaria.

5.2.2 RENDIMIENTO DE LOS MODELOS

Tabla 3. Rendimiento de los modelos de clasificación: AUC de resustitución frente a AUC validado (LOO).

Modelo / predictores	AUC resustitución	AUC validado (LOO)
Logística (solo sociodemográficas)	0,782	0,259
Logística (solo psicométricas)	0,723	0,290
Logística (combinado: socio + psicométricas)	0,890	0,256
Gradient boosting (combinado)	1,000	0,390
Clasificador trivial (clase mayoritaria)	—	0,500

Los resultados de la Tabla 3 admiten tres lecturas. Primera, el desplome entre el AUC de resustitución y el validado es muy grande y crece al añadir predictores: la logística sobre las variables psicométricas pasa de 0,723 a 0,290, la combinada de 0,890 a 0,256 y el gradient boosting de 1,000 a 0,390, lo que evidencia un sobreajuste severo propio del régimen de muestra pequeña. Segunda, todos los AUC validados quedan en torno a 0,5 o por debajo, de modo que ningún modelo discrimina por encima del azar; los valores ligeramente inferiores a 0,5 son consistentes con el sesgo pesimista del estimador LOO con muestras pequeñas, que el estudio de simulación reproduce. Tercera, los modelos rinden de forma equivalente y ninguna supera al clasificador trivial, lo que indica que ninguno de los modelos considerados detecta señal predictiva. Este resultado no permite concluir que no exista señal, sino que, de existir, no es detectable con estos modelos y con el tamaño muestral disponible (véase el análisis de potencia del apartado 5.4).

5.2.3 SIGNIFICACIÓN Y VALIDEZ INCREMENTAL

La significación del mejor modelo se evalúa mediante un test de permutación de las etiquetas. La validez incremental del bloque psicométrico se valora comparando el modelo combinado con el modelo que solo incluye variables sociodemográficas.




Figura 2. Distribución nula del AUC por permutación, con el AUC observado señalado.

El test de permutación sobre el mejor modelo confirma la ausencia de significación: el AUC observado no supera el percentil 95 de la distribución nula y queda incluso por debajo de su mediana, con un p-valor de 0,869 (Figura 2). La validez incremental del bloque psicométrico sobre el sociodemográfico, y la del grit sobre la batería, es nula: añadir predictores no mejora el rendimiento validado.

5.3 DIAGNÓSTICO DE MECANISMOS

Establecido el resultado predictivo, este capítulo investiga sus causas mediante dos análisis: la restricción de rango y la infrapotencia estadística.

5.3.1 RESTRICCIÓN DE RANGO: CORRECCIÓN DE THORNDIKE

Partiendo del efecto techo documentado en el apartado 5.1 (apartado «**Efecto techo: contraste con las normas poblacionales**»), se estima en qué medida la preselección atenúa las correlaciones predictor-criterio. Se aplica la corrección de Thorndike (caso II; Cap. 3,

apartado «**Restricción de rango**»), usando como desviaciones típicas no restringidas las de las normas poblacionales publicadas.

Tabla 4. Corrección de Thorndike por restricción de rango: desviaciones típicas, ratio U y correlaciones observada y corregida por dimensión.

Dimensión	DT muestra	DT norma	$U = S/s$	r observada	r corregida
Autoeficacia	5,340	5,050	0,940	-0,107	-0,101
Autonomía	5,030	4,980	0,990	0,047	0,046
Innovación	4,900	4,500	0,920	-0,097	-0,089
Locus interno	6,320	5,360	0,850	0,066	0,056
Motivación de logro	4,940	4,430	0,900	-0,113	-0,101
Optimismo	5,660	5,270	0,930	-0,154	-0,144
Tolerancia al estrés	5,700	6,570	1,150	-0,218	-0,250
Toma de riesgos	5,010	5,310	1,060	-0,160	-0,169




Figura 3. Corrección de Thorndike por restricción de rango: correlaciones observadas frente a corregidas.

La corrección de Thorndike (Tabla 4 y Figura 3) apenas modifica las correlaciones: solo las eleva en las dos dimensiones con $U > 1$ (la de mayor magnitud, tolerancia al estrés, pasa de $-0,218$ a $-0,250$) y las reduce ligeramente en el resto, de modo que ninguna dimensión alcanza, una vez desatenuada, un valor que implicara una validez de criterio útil.

5.3.2 INFRAPOTENCIA: EFECTO MÍNIMO DETECTABLE Y TAMAÑO MUESTRAL REQUERIDO

Se calcula el efecto mínimo detectable (MDE) con el tamaño muestral disponible, y el tamaño muestral que se requeriría para detectar, con potencia 0,80, los efectos plausibles del dominio (Tabla 5). Estos efectos se anclan en evidencia externa: el efecto global del contraste autónomos-empleados de la validación de la BEPE ($d \approx 0,35$) y el rango del meta-análisis de Rauch y Frese [1], nunca en el efecto observado en la muestra.

Tabla 5. Análisis de potencia: tamaño del efecto, AUC teórico equivalente y tamaño muestral requerido por grupo y total.

Efecto verdadero (d)	AUC teórico ($\Phi(d/\sqrt{2})$)	n por grupo	n total
0,20	0,556	394	788
0,35 (ancla BEPE)	0,598	130	260
0,50	0,638	64	128
MDE actual = 0,93	0,745	—	41 (26/15)




Figura 4. Curva de potencia frente al tamaño muestral para distintos tamaños del efecto, con el efecto mínimo detectable de la muestra.

Con la muestra disponible (26 casos de éxito y 15 de no-éxito), el efecto mínimo detectable es $d = 0,93$ (equivalente a un AUC de 0,745), muy por encima de los efectos plausibles del dominio (Figura 4). Para detectar un efecto realista ($d = 0,35$) con potencia 0,80, el cálculo prescribe aproximadamente 130 casos por grupo (unos 260 en total); para un efecto pequeño ($d = 0,20$), cerca de 394 por grupo. El estudio se encontraba, por tanto, infrapotenciado desde su diseño para los efectos que cabía esperar.

5.4 SIMULACIÓN DE MONTE CARLO

El diagnóstico del apartado 5.3 emplea fórmulas de contraste simple. Para estimar la potencia del procedimiento completo —clasificación regularizada con validación cruzada, predictores correlacionados, techo y desbalanceo, que ninguna fórmula cerrada describe— se construye una simulación Monte Carlo. Este es el capítulo de mayor contenido

metodológico propio del trabajo, y su protocolo se desarrolla en detalle en el documento de diseño adjunto.

5.4.1 DISEÑO DEL GENERADOR

El generador sintetiza candidatos a nivel de ítem reproduciendo la estructura bifactor publicada de la BEPE: para cada sujeto se extrae un factor general y ocho factores específicos, y la respuesta latente a cada uno de los 80 ítems se compone según sus cargas [2, Tabla 2], se discretiza a la escala Likert de cinco categorías y se suma por dimensiones. El grit se genera con carga en el factor general y en el específico de motivación de logro. El criterio se genera desde el factor general latente mediante un modelo logístico, con el coeficiente calibrado numéricamente al tamaño de efecto verdadero de cada escenario y la constante calibrada a la tasa base real. La preselección se modela de forma explícita: de un conjunto amplio de aspirantes se retiene la fracción superior según la puntuación total, lo que reproduce la restricción de rango por su mecanismo causal.

Las decisiones de diseño —situar el efecto en el factor latente y no en las puntuaciones observadas, generar a nivel de ítem, y modelar la selección explícitamente— responden a la necesidad de que la simulación reproduzca la cadena completa de degradación de la señal (constructo → medida con error → suma → techo → preselección) que opera en la realidad, y no una versión simplificada que sobrestimaría la potencia. La justificación pormenorizada de cada decisión figura en el documento de protocolo.




Figura 5. Validación del generador: calibración de las puntuaciones simuladas frente a la muestra real.

5.4.2 VALIDACIÓN DEL GENERADOR

Antes de producir resultados, el generador debe superar tres controles: reproducir las medias, las desviaciones típicas, la estructura de correlación y el grado de saturación de la muestra real (calibración); arrojar una tasa de detección igual al nivel de significación cuando el efecto verdadero es nulo (control del error de tipo I); y detectar de forma fiable un efecto grande en condiciones favorables (recuperación de parámetros).

El generador superó los tres controles de validación exigidos (Figura 5). En la calibración, reprodujo dentro de la tolerancia las medias, la intercorrelación media y el grado de saturación de la muestra real. En el control de error de tipo I, las celdas con efecto nulo arrojaron una tasa de detección del 5 %, confirmada con réplicas nulas independientes (0,062 y 0,056). En la recuperación de parámetros, la celda de efecto grande y muestra amplia ($n = 500$, $d = 0,8$) detectó en el 100 % de las réplicas, con un AUC de 0,698 muy próximo al teórico sin error de medida (0,714); el pequeño déficit corresponde precisamente a la atenuación por error de medida que el generador debe reproducir.




Figura 6. Mapa de detectabilidad: potencia del procedimiento según tamaño muestral y tamaño del efecto, con el caso real señalado.

5.4.3 POTENCIA DEL PROCEDIMIENTO, CURVA DE APRENDIZAJE Y MAPA DE DETECTABILIDAD

Sobre una rejilla de tamaños muestrales, tamaños de efecto y severidades de preselección, se generan numerosas réplicas por celda, se ejecuta en cada una el procedimiento completo y se calcula la proporción de réplicas que detectan el efecto (la potencia). De aquí se derivan

tres productos: la potencia del caso real, la curva de aprendizaje (AUC validado frente a n) y el mapa de detectabilidad (potencia en función de n y del efecto, por nivel de preselección).

Tabla 6. Potencia del procedimiento estimada por simulación según el tamaño muestral, para distintos tamaños del efecto y el control de error de tipo I.

Celda (preselección $\tau \approx 0,9$)	$n = 41$	$n = 120$	$n = 300$	$n = 500$
$d = 0,35$	0,104	0,274	0,616	0,766
$d = 0,50$	0,184	0,486	0,886	0,986
$d = 0$ (control, error tipo I)	0,050	0,050	0,050	0,050




Figura 7. Análisis de sensibilidad: potencia para un efecto realista ($d = 0,35$) en las distintas variantes del generador.

La potencia del procedimiento en el caso real ($n = 41$) es muy baja (Tabla 6): 0,058, 0,104, 0,184 y 0,354 para efectos de $d = 0,2$, 0,35, 0,5 y 0,8 respectivamente. La curva de aprendizaje muestra que, para un efecto realista ($d = 0,35$), la potencia no alcanza el umbral de 0,80 ni siquiera con $n = 500$ (se queda en 0,766), y el AUC mediano apenas sube de 0,51

a 0,58 en ese recorrido. El mapa de detectabilidad (Figura 6) sitúa el caso real holgadamente por debajo de la región detectable, y muestra que la preselección calibrada cuesta poca potencia: el factor dominante es el tamaño muestral, no el techo.

5.4.4 ANÁLISIS DE SENSIBILIDAD

La robustez de las conclusiones se examina variando los supuestos del generador: un generador alternativo a nivel de escala mediante cópula, la ubicación del efecto en factores específicos en lugar del general, distintas tasas base y distintas funciones de enlace.

El resultado central es robusto a las variantes del generador (Figura 7). La potencia para $d = 0,35$ en el caso real se mantiene entre 0,08 y 0,11 en las ocho configuraciones probadas (bifactor y LOO, cópula empírica, efecto en factores específicos, tasa base 50/50, enlace probit, mezcla de enseñanzas y estabilidad con $M = 1000$). De forma decisiva, los dos generadores —el bifactor anclado en parámetros publicados y la cópula anclada en la muestra— convergen, lo que indica que la conclusión es del problema y no del simulador. La única variante más exigente es la que sitúa el efecto en los factores específicos: si la señal viviera en dimensiones de grupo y no en el factor general, ni $n = 500$ bastaría, un matiz que conviene tener presente.

Capítulo 6. DISCUSIÓN

6.1 INTERPRETACIÓN DE LOS RESULTADOS A LA LUZ DE LA LITERATURA

Los resultados de este trabajo deben interpretarse en el contexto de lo que la literatura ya documenta, con la que son plenamente coherentes. El hallazgo de una validez de criterio escasa no constituye una anomalía de esta muestra, sino la réplica en un caso aplicado de un patrón conocido: en la propia validación de la BEPE, con una muestra veinte veces mayor, el conjunto de escalas explicaba en torno al 5 % de la varianza del estatus emprendedor, mientras predecía con gran precisión la pertenencia a grupos extremos de otras medidas de personalidad [2]; y la tesis doctoral del mismo programa cifra en torno al 2,6 % la varianza de convertirse en trabajador por cuenta propia explicada por la personalidad emprendedora [4]. El meta-análisis de referencia sitúa además las correlaciones rasgo-éxito en un máximo de $r \approx 0,30$ (motivación de logro), con la mayoría de los rasgos por debajo [1]. En este marco, la ausencia de asociación estimable en una muestra de 41 casos no es un hallazgo sorprendente, sino exactamente lo que cabría predecir: si estudios con más de mil participantes apenas alcanzan un 5 % de varianza explicada, ninguna muestra de este tamaño podría detectar de forma fiable un efecto tan pequeño. La paradoja —el instrumento predice tests, pero apenas predice conducta— se explica por la compensación entre amplitud y fidelidad de los rasgos (Cap. 2, apartado «**Validez: evidencias de constructo y de criterio**»): un rasgo de banda ancha como la personalidad emprendedora describe bien el perfil general, pero predice con dificultad un criterio tan específico y multicausal como el éxito de una franquicia. El problema no está, por tanto, en la calidad psicométrica del test, que es elevada, sino en la distancia estructural entre el constructo y la conducta, mediada por innumerables factores situacionales que ningún autoinforme captura.

El caso del grit refuerza esta lectura. Su asociación con el criterio es prácticamente nula ($r = 0,027$) y su fuerte correlación con la motivación de logro indica solapamiento conceptual

antes que aportación incremental, en línea con las revisiones que han cuestionado el valor predictivo diferencial del grit sobre rasgos ya conocidos.

Conviene subrayar una distinción que la interpretación no debe pasar por alto: que la personalidad prediga poco el éxito no implica que la BEPE sea un mal instrumento. La batería mide con solvencia el constructo que dice medir; lo que es débil es la relación entre ese constructo y el desempeño, que depende además de numerosos factores —capital, ubicación, sector, gestión, contexto— ajenos a la personalidad. Validez de constructo y validez de criterio son, como se argumentó en el Capítulo 2, lógicamente independientes.

6.2 LA CADENA DE MECANISMOS

El valor explicativo del trabajo reside en descomponer el resultado en una cadena de mecanismos cuantificados que explican por qué el perfil psicométrico no permite predecir el éxito en estas condiciones; cada eslabón degrada la señal, y su efecto combinado basta para explicar el resultado sin postular que los rasgos sean irrelevantes.

El primer eslabón es la debilidad del efecto en la población de origen: la literatura sitúa el techo de lo explicable por la personalidad en valores muy bajos ($r \approx 0,30$ en el mejor rasgo; en torno al 5 % de varianza para el conjunto). El segundo es el error de medida del instrumento, que atenúa toda relación observada y que el estudio de simulación incorpora al situar el efecto en el factor latente —razón por la que el AUC recuperado (0,698) queda por debajo del teórico sin error (0,714)—. El tercero es la restricción de rango por preselección, que la corrección de Thorndike cuantifica como moderada (la mayor correlación pasa de $-0,218$ a $-0,250$) y que no oculta por sí sola una validez útil. El cuarto es la infrapotencia estadística: con $n = 41$ el efecto mínimo detectable es $d = 0,93$, y la potencia para un efecto realista es de solo 0,104, sin alcanzar 0,80 ni con $n = 500$.

La conclusión de la cadena es que estos cuatro mecanismos —efecto pequeño de origen, atenuado por el error de medida, comprimido por la preselección y sometido a un diseño infrapotente— son conjuntamente suficientes para explicar la ausencia de capacidad

predictiva. El resultado nulo no es un fracaso del análisis, sino la consecuencia esperable y cuantificada de una señal débil examinada en condiciones desfavorables.

6.3 *IMPLICACIONES PARA LA PRÁCTICA DE LA SELECCIÓN*

Para la práctica de la selección de franquiciados, la implicación es que emplear un instrumento —por excelente que sea su validez de constructo— sin haber establecido su validez de criterio local equivale a tomar decisiones sobre una base no contrastada. La literatura advierte, además, que el criterio de éxito es el punto débil estructural del área, y que la mera condición de autónomo no equivale a espíritu emprendedor [36]. La aportación constructiva del trabajo es la prescripción cuantitativa de las condiciones que un estudio de validación concluyente requeriría.

Este punto enlaza con el uso responsable de la inteligencia artificial (Cap. 3, apartado «**Interpretabilidad y uso responsable de los modelos**»). El proyecto se concibió para producir un *score* de probabilidad de éxito como apoyo a la decisión, pero un *score* derivado de un modelo sin validez predictiva no es una ayuda neutral: revestiría de apariencia objetiva y tecnológica una decisión que en realidad no está informada por los datos, con el riesgo añadido de introducir sesgos difíciles de auditar. La conclusión responsable, coherente con los principios de la IA interpretable, no es entregar el *score* con advertencias, sino **no desplegarlo** mientras no se satisfagan las condiciones de validez que el trabajo cuantifica. El sistema interpretable cumple aquí su función más valiosa: hacer visible que no hay nada que desplegar.

6.4 *AMENAZAS A LA VALIDEZ DE ESTE TRABAJO*

La honestidad metodológica exige examinar de forma explícita las amenazas a la validez de las propias conclusiones.

Diseño transversal y retrospectivo. La evaluación psicométrica y el cuestionario se administraron cuando los participantes ya eran franquiciados y su desenlace era conocido;

los predictores no se midieron antes del criterio, sino simultáneamente a su conocimiento. Esto impide hablar de predicción en sentido causal estricto y abre la posibilidad de que la propia experiencia de éxito o fracaso haya influido en las respuestas al cuestionario. Por ello el trabajo se plantea como estudio de asociación y de viabilidad, no como validación prospectiva.

Validez de la definición del criterio. El criterio no fue homogéneo entre enseñanzas: cada central aplicó su propia definición interna de éxito, que este documento no reproduce por acuerdo de confidencialidad. La variable dependiente no mide, por tanto, exactamente lo mismo en ambos subgrupos, lo que introduce ruido al agruparlas; el análisis por enseñanza se incorpora como verificación de robustez ante esta amenaza.

Subjetividad del componente cualitativo. Una de las enseñanzas incorporó en su criterio un componente de juicio experto, sin protocolo estandarizado ni medida de fiabilidad entre evaluadores, lo que introduce una subjetividad que no puede cuantificarse con los datos disponibles.

Validez interna y externa. La muestra está preseleccionada (restricción de rango) y es pequeña ($n = 41$), procedente de solo dos enseñanzas de sectores específicos; las cifras cuantitativas, en particular el tamaño muestral prescrito, deben entenderse como caracterización de las condiciones de viabilidad en este contexto y no como estimaciones generalizables.

Alcance de la conclusión. El trabajo demuestra que el procedimiento es correcto y que detectaría una señal de tamaño realista si existiera y la muestra fuera suficiente; lo que no puede determinar es si la ausencia de señal se debe al instrumento, a que la personalidad no prediga el éxito en franquicia, o a las condiciones del diseño. Discriminar entre esas explicaciones excede el alcance de este trabajo.

Capítulo 7. CONCLUSIONES Y LÍNEAS FUTURAS

7.1 CONCLUSIONES

A continuación se responde, una a una, a las contribuciones planteadas en la Introducción (apartado «Contribuciones»).

C1 (relación predictor-criterio): ninguna variable mostró asociación estadísticamente fiable con el criterio; la correlación de mayor magnitud fue la de tolerancia al estrés ($r = -0,218$; IC 95 % $[-0,493; 0,096]$), cuyo intervalo incluye el cero, y el grit fue prácticamente nulo ($r = 0,027$). Todas las correlaciones son compatibles con la ausencia de efecto.

C2 (capacidad predictiva): el AUC validado (LOO) de los modelos quedó en torno a 0,29 —en o por debajo del azar (0,5)— frente a un AUC de resustitución de hasta 0,89 en la logística y de 1,00 en gradient boosting, evidenciando sobreajuste; el test de permutación no fue significativo ($p = 0,869$) y los modelos rindieron de forma equivalente (todas en o bajo el azar).

C3 (mecanismos): la corrección de Thorndike por restricción de rango apenas desatenúa las correlaciones (la mayor, tolerancia al estrés, pasa de $-0,218$ a $-0,250$), de modo que la restricción de rango no enmascara una validez útil; el efecto mínimo detectable con la muestra real (26/15) es $d = 0,93$ ($AUC \approx 0,745$), muy por encima de los efectos plausibles del dominio.

C4 (simulación): la potencia del procedimiento en el caso real ($n = 41$) para un efecto realista ($d = 0,35$) es de solo 0,104; para alcanzar una potencia de 0,80 con ese efecto el análisis de potencia clásico prescribe ≈ 130 casos por grupo (≈ 260 en total) y la simulación calibrada no cruza ese umbral ni con $n = 500$, lo que sitúa la muestra disponible muy por debajo del mínimo viable.

C5 (validez incremental y grit): el bloque psicométrico no aporta capacidad predictiva apreciable sobre el criterio, y el grit, fuertemente correlacionado con motivación de logro, no añade validez incremental sobre la batería (su asociación con el criterio es prácticamente nula, $r = 0,027$).

C6 (interpretabilidad y uso responsable): el análisis de interpretabilidad confirma, en lugar de explicar un modelo válido, que ningún predictor contribuye de forma estable; en consecuencia, el sistema no debe emplearse como apoyo a la decisión de selección, y su valor reside en haber delimitado con rigor esa imposibilidad.

7.2 LIMITACIONES

Las principales limitaciones del trabajo son el tamaño muestral, inherente al caso de estudio; la incertidumbre sobre la definición operativa del criterio; la indisponibilidad de las respuestas a los ítems individuales, que impide un análisis basado en la teoría de respuesta al ítem sobre la propia muestra; y la circunscripción a dos enseñanzas concretas, que limita la generalización.

7.3 LÍNEAS FUTURAS

El resultado de este trabajo delimita con precisión qué no permite concluir y, con ello, señala la dirección en que la investigación debe avanzar. Lo establecido es que un único instrumento de autoinforme, centrado en un solo dominio de constructo —la personalidad emprendedora—, administrado en una muestra pequeña y preseleccionada y contrastado contra un criterio heterogéneo, no alcanza validez predictiva apreciable. Lo que no se ha puesto a prueba, y queda abierto, es la capacidad de un dispositivo de evaluación sustancialmente más completo. La restricción a una sola prueba responde al carácter exploratorio del estudio y a condicionantes reales de coste y de tiempo de administración, y constituye en sí misma una limitación del diseño antes que una propiedad del dominio.

La primera línea, ya enunciada en términos de muestra y criterio, es un estudio de validación local con el tamaño muestral que la simulación prescribe, un criterio de éxito multidimensional definido a priori y homogéneo entre enseñanzas y, preferiblemente, una evaluación previa a la preselección que preserve la varianza. Sin un criterio bien definido — el punto estructuralmente débil del área—, ninguna ampliación del lado predictor basta por sí sola.

La segunda línea es la ampliación del propio dispositivo de medida, y es donde cabe esperar la mayor ganancia. Un solo autoinforme confunde el rasgo con el método y arrastra un error de medida irreducible que, como se argumentó, atenúa toda relación observada. Frente a ello, una batería concebida como sistema multimétodo y multifuente —que combine varios indicadores del mismo constructo para reducir el error de medida, desatenuando las correlaciones, e incorpore dominios distintos con validez incremental sobre la personalidad— está en mejores condiciones de capturar la varianza del criterio. Entre esos dominios, la evidencia acumulada en selección de personal sitúa la capacidad cognitiva general entre los predictores de mayor validez de criterio y en buena medida independiente de la personalidad ([37], con las estimaciones revisadas en [38]); a ella se añaden los valores, las competencias y los datos biográficos estructurados (biodata), cuya capacidad predictiva del desempeño compite con la de los tests de personalidad. La integración de fuentes — autoinforme, heteroinforme y registros objetivos— reduciría además el sesgo de método común y permitiría, por fin, controlar la deseabilidad social que en este trabajo no ha podido cuantificarse.

La tercera línea reconoce la naturaleza multicausal del criterio que la propia discusión subraya. El éxito de una franquicia depende de factores que ningún rasgo individual capta —capital, ubicación, sector, gestión, contexto de mercado—. Un modelo que, junto a las variables individuales, incorpore predictores de nivel familiar, regional y de mercado, en la línea de la investigación que aboga por integrar múltiples fuentes y niveles de análisis [4], se ajustaría mejor a la estructura del fenómeno. La pregunta deja entonces de ser si la personalidad predice el éxito —se sabe que lo hace de forma modesta— y pasa a ser cuánta

varianza del criterio recupera un sistema de evaluación multidominio, multifuente y multinivel correctamente construido y validado.

Conviene, por último, no incurrir en el optimismo inverso al error que este trabajo previene. Ampliar el dispositivo de medida es condición necesaria, pero el techo de lo predecible lo fija también la naturaleza del criterio: incluso una batería potente operará sobre un fenómeno multicausal y, en parte, irreductiblemente contingente. La aportación de este trabajo no es clausurar la cuestión, sino cuantificar las condiciones —tamaño muestral, definición del criterio, amplitud y calidad del dispositivo de medida— bajo las cuales merecería la pena volver a plantearla. En el plano instrumental, disponer de las respuestas a los ítems permitiría un análisis psicométrico más fino (teoría de respuesta al ítem) y la conexión con las versiones adaptativas computarizadas de la BEPE, y el generador de simulación desarrollado queda como herramienta reutilizable para dimensionar esos estudios de validación antes de ejecutarlos.

REFERENCIAS

- [1] A. Rauch and M. Frese, “Let’s put the person back into entrepreneurship research: A meta-analysis on the relationship between business owners’ personality traits, business creation, and success,” *European Journal of Work and Organizational Psychology*, vol. 16, no. 4, pp. 353–385, 2007.
- [2] M. Cuesta, J. Suárez-Álvarez, L. M. Lozano, E. García-Cueto, and J. Muñiz, “Assessment of eight entrepreneurial personality dimensions: Validity evidence of the BEPE battery,” *Frontiers in Psychology*, vol. 9, Art. no. 2352, 2018.
- [3] A. L. Duckworth, C. Peterson, M. D. Matthews, and D. R. Kelly, “Grit: Perseverance and passion for long-term goals,” *Journal of Personality and Social Psychology*, vol. 92, no. 6, pp. 1087–1101, 2007.
- [4] Á. Postigo, “Medición de los rasgos psicológicos de la persona emprendedora,” Tesis doctoral, Universidad de Oviedo, Oviedo, España, 2021.
- [5] L. J. Cronbach, “Coefficient alpha and the internal structure of tests,” *Psychometrika*, vol. 16, no. 3, pp. 297–334, 1951.
- [6] R. P. McDonald, *Test Theory: A Unified Treatment*. Mahwah, NJ, USA: Lawrence Erlbaum Associates, 1999.
- [7] American Educational Research Association, American Psychological Association, and National Council on Measurement in Education, *Standards for Educational and Psychological Testing*. Washington, DC, USA: AERA, 2014.
- [8] O. P. John, L. P. Naumann, and C. J. Soto, “Paradigm shift to the integrative Big Five trait taxonomy: History, measurement, and conceptual issues,” in *Handbook of Personality: Theory and Research*, 3.^a ed., O. P. John, R. W. Robins, and L. A. Pervin, Eds. Nueva York, NY, USA: Guilford Press, 2008, pp. 114–158.
- [9] C. J. Soto and O. P. John, “The next Big Five Inventory (BFI-2): Developing and assessing a hierarchical model,” *Journal of Personality and Social Psychology*, vol. 113, no. 1, pp. 117–143, 2017.
- [10] H. Zhao, S. E. Seibert, and G. T. Lumpkin, “The relationship of personality to entrepreneurial intentions and performance: A meta-analytic review,” *Journal of Management*, vol. 36, no. 2, pp. 381–404, 2010.

- [11] H. Brandstätter, “Personality aspects of entrepreneurship: A look at five meta-analyses,” *Personality and Individual Differences*, vol. 51, no. 3, pp. 222–230, 2011.
- [12] F. Leutner, G. Ahmetoglu, R. Akhtar, and T. Chamorro-Premuzic, “The relationship between the entrepreneurial personality and the Big Five personality traits,” *Personality and Individual Differences*, vol. 63, pp. 58–63, 2014.
- [13] A. Albert and J. A. Anderson, “On the existence of maximum likelihood estimates in logistic regression models,” *Biometrika*, vol. 71, no. 1, pp. 1–10, 1984.
- [14] R. Tibshirani, “Regression shrinkage and selection via the lasso,” *Journal of the Royal Statistical Society: Series B*, vol. 58, no. 1, pp. 267–288, 1996.
- [15] H. Zou and T. Hastie, “Regularization and variable selection via the elastic net,” *Journal of the Royal Statistical Society: Series B*, vol. 67, no. 2, pp. 301–320, 2005.
- [16] V. N. Vapnik, *Statistical Learning Theory*. Nueva York, NY, USA: Wiley, 1998.
- [17] P. L. Bartlett and S. Mendelson, “Rademacher and Gaussian complexities: Risk bounds and structural results,” *Journal of Machine Learning Research*, vol. 3, pp. 463–482, 2002.
- [18] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2.^a ed. Nueva York, NY, USA: Springer, 2009.
- [19] S. Varma and R. Simon, “Bias in error estimation when using cross-validation for model selection,” *BMC Bioinformatics*, vol. 7, Art. no. 91, 2006.
- [20] G. C. Cawley and N. L. C. Talbot, “On over-fitting in model selection and subsequent selection bias in performance evaluation,” *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.
- [21] M. Ojala and G. C. Garriga, “Permutation tests for studying classifier performance,” *Journal of Machine Learning Research*, vol. 11, pp. 1833–1863, 2010.
- [22] R. L. Thorndike, *Personnel Selection: Test and Measurement Techniques*. Nueva York, NY, USA: Wiley, 1949.
- [23] P. R. Sackett and H. Yang, “Correction for range restriction: An expanded typology,” *Journal of Applied Psychology*, vol. 85, no. 1, pp. 112–118, 2000.
- [24] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2.^a ed. Hillsdale, NJ, USA: Lawrence Erlbaum Associates, 1988.
- [25] A. Gelman and J. Carlin, “Beyond power calculations: Assessing type S (sign) and type M (magnitude) errors,” *Perspectives on Psychological Science*, vol. 9, no. 6, pp. 641–651, 2014.
- [26] J. M. Hoenig and D. M. Heisey, “The abuse of power: The pervasive fallacy of power calculations for data analysis,” *The American Statistician*, vol. 55, no. 1, pp. 19–24, 2001.

- [27] F. Doshi-Velez and B. Kim, “Towards a rigorous science of interpretable machine learning,” arXiv preprint arXiv:1702.08608, 2017.
- [28] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 2.^a ed., 2022. [En línea]. Disponible en: <https://christophm.github.io/interpretable-ml-book>
- [29] J. Muñoz, J. Suárez-Álvarez, I. Pedrosa, E. Fonseca-Pedrero, and E. García-Cueto, “Enterprising personality profile in youth: Components and assessment,” *Psicothema*, vol. 26, no. 4, pp. 545–553, 2014.
- [30] J. Suárez-Álvarez, I. Pedrosa, E. García-Cueto, and J. Muñoz, “Screening enterprising personality in youth: An empirical model,” *The Spanish Journal of Psychology*, vol. 17, Art. no. E60, 2014.
- [31] Á. Postigo, E. García-Cueto, M. Cuesta, Á. Menéndez-Aller, F. Prieto-Díez, and L. M. Lozano, “Assessment of the enterprising personality: A short form of the BEPE battery,” *Psicothema*, vol. 32, no. 4, pp. 575–582, 2020.
- [32] Á. Postigo, E. García-Cueto, J. Muñoz, C. González-Nuevo, and M. Cuesta, “Measurement invariance of entrepreneurial personality in relation to sex, age, and self-employment,” *Current Psychology*, vol. 42, pp. 3160–3170, 2023.
- [33] I. Pedrosa, J. Suárez-Álvarez, E. García-Cueto, and J. Muñoz, “A computerized adaptive test for enterprising personality assessment in youth,” *Psicothema*, vol. 28, no. 4, pp. 471–478, 2016.
- [34] S. A. Birkeland, T. M. Manson, J. L. Kisamore, M. T. Brannick, and M. A. Smith, “A meta-analytic investigation of job applicant faking on personality measures,” *International Journal of Selection and Assessment*, vol. 14, no. 4, pp. 317–335, 2006.
- [35] Á. Postigo, M. Cuesta, and E. García-Cueto, “Entrepreneurial personality, conscientiousness, self-control, and grit: The psychological side of self-employment,” *Anales de Psicología*, vol. 37, no. 2, pp. 361–370, 2021.
- [36] M. Henrekson and T. Sanandaji, “Small business activity does not measure entrepreneurship,” *Proceedings of the National Academy of Sciences*, vol. 111, no. 5, pp. 1760–1765, 2014.
- [37] F. L. Schmidt and J. E. Hunter, “The validity and utility of selection methods in personnel psychology: Practical and theoretical implications of 85 years of research findings,” *Psychological Bulletin*, vol. 124, no. 2, pp. 262–274, 1998.
- [38] P. R. Sackett, C. Zhang, C. M. Berry, and F. Lievens, “Revisiting meta-analytic estimates of validity in personnel selection: Addressing systematic overcorrection for range restriction,” *Journal of Applied Psychology*, vol. 107, no. 11, pp. 2040–2068, 2022.

ANEXOS

Todo el material complementario de este Trabajo (código, datos, resultados y documentos de soporte) se encuentra en el repositorio de GitHub asociado a la memoria:

<https://github.com/berordas/tfg-prediccion-exito-franquicia>

La organización del repositorio y las instrucciones de reproducción se describen en su archivo README.md.

ANEXO A. CÓDIGO Y REPRODUCIBILIDAD

El código completo del análisis está en la carpeta src/ del repositorio. El README.md documenta la versión de Python, las dependencias (requirements.txt), las semillas aleatorias y el orden de ejecución de los scripts para reproducir íntegramente los resultados, tablas y figuras de esta memoria.

ANEXO B. TABLAS COMPLETAS Y DIAGNÓSTICOS DE LA SIMULACIÓN

Las tablas extensas y los diagnósticos completos —la matriz de intercorrelaciones entre las dimensiones de la BEPE, los resultados por celda del estudio de simulación y las tablas de calibración y validación del generador— están en la carpeta resultados/ del repositorio.

ANEXO C. PLAN DE ANÁLISIS PRERREGISTRADO

El plan de análisis prerregistrado, fechado y tal como se fijó antes de ejecutar los análisis, junto con el registro de las desviaciones documentadas, está en el archivo resultados/cap7_preregistro.md del repositorio.

ANEXO D. CONJUNTO DE DATOS SEUDONIMIZADO Y PROCEDIMIENTO DE SEUDONIMIZACIÓN

El análisis se ha realizado sobre una versión seudonimizada del fichero original (data/dataset_franquicias_seudonimizado.xlsx en el repositorio). El procedimiento de seudonimización aplicado fue el siguiente: (i) se eliminó la columna de correo electrónico, identificador directo; (ii) se eliminó la columna de código original, reidentificable al estar construida a partir de las iniciales y, presumiblemente, el año de nacimiento; (iii) se introdujo un identificador arbitrario (sujeto_id, de S001 a S045) sin relación con ningún atributo de la persona; y (iv) se barajó el orden de los registros. Se conservan las 27 variables de análisis (8 dimensiones BEPE en puntuación directa y percentil, puntuación global, grit y variables sociodemográficas) y el criterio. La tabla de correspondencia entre el identificador arbitrario y los datos originales se conserva de forma separada y segura por el equipo responsable y no forma parte del repositorio, en coherencia con la distinción entre seudonimización y anonimización (Cap. 4, apartado «**Consideraciones éticas y protección de datos**»): el conjunto sigue siendo dato personal seudonimizado y el acceso al repositorio se limita al tribunal.